HDFS及其接口应用

0. Refs

```
https://dblab.xmu.edu.cn/blog/2460/
```

1. HDFS简介

Hadoop Distributed File System,Hadoop分布式文件系统。实际本质上也是个文件系统，但是它高度抽象，隐藏了众多细节，让用户感知不到TA正在使用一个分布式文件系统的同时，又能应用到DFS的分布式存储架构的优势。

1.1. 命令行接口

既然是个文件系统，必然有其对应的接口。hadoop提供了三种shell命令方式与dfs交互：

1. hadoop fs：适用于任何不同的文件系统，比如本地文件系统和HDFS文件系统
2. hadoop dfs：只能适用于HDFS文件系统
3. hdfs dfs：跟hadoop dfs的命令作用一样，也只能适用于HDFS文件系统

可以使用-help选项查看各个命令如何使用，例如:

```
./bin/hadoop fs -help put
```

其实光靠猜也能大概猜出来每条命令咋用的，比如put就是把本地的文件上传到hdfs里面去，get就是把hdfs里的某些文件拉取到本地文件系统中，mkdir就是在hdfs中创建一个文件夹等等...

1.2. JAVA API

当我们遇到一个非常复杂的任务时，就不能仅靠命令行和hdfs交互了（得输入非常多的命令），这个时候最好是以代码脚本的方式和hdfs交互。Apache他们的生态就是Java系的，因此java社区中支持了一套完整且丰富的API，以供开发者和用户与hdfs交互。

java的开发环境我并没有像ref中的教程一样选择Eclipse，我个人偏爱jetbrain旗下的idea。因此我在我的ubuntu虚拟机里配了一个idea的集成开发环境。

首先我们hadoop的接口是以jar包形式提供的，所以要在项目的lib中集成这些jar包。这些jar包包括：

（1）“/usr/local/hadoop/share/hadoop/common”目录下的所有JAR包，包括hadoop-common-3.1.3.jar、hadoop-common-3.1.3-tests.jar、haoop-nfs-3.1.3.jar和haoop-kms-3.1.3.jar，注意，不包括目录jdiff、lib、sources和webapps；

（2）“/usr/local/hadoop/share/hadoop/common/lib”目录下的所有JAR包；

（3）“/usr/local/hadoop/share/hadoop/hdfs”目录下的所有JAR包，注意，不包括目录jdiff、lib、sources和webapps；

（4）“/usr/local/hadoop/share/hadoop/hdfs/lib”目录下的所有JAR包。

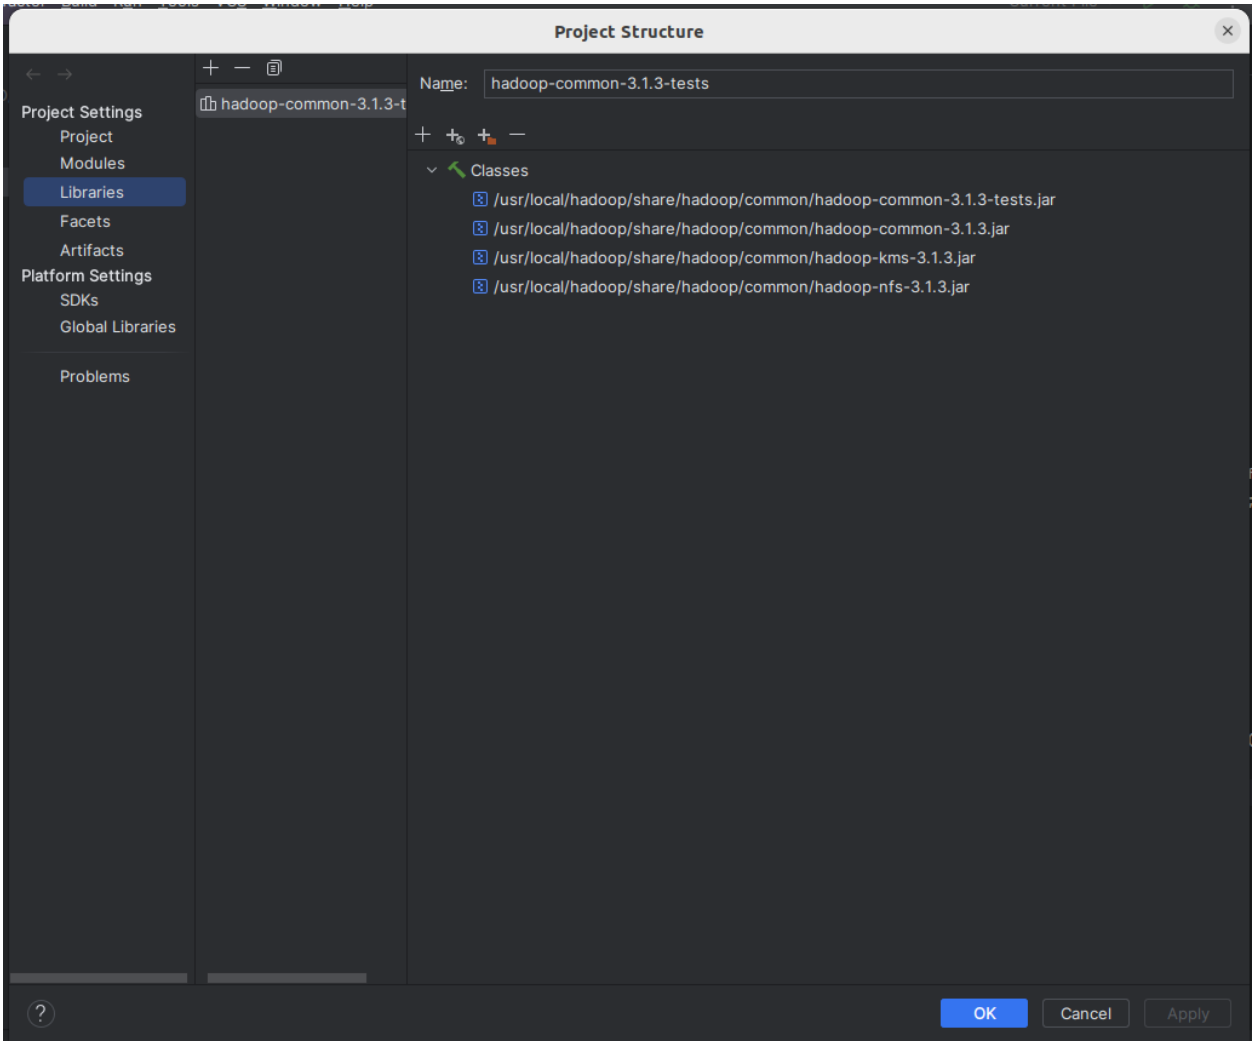

之后就可以编写代码，使用hdfs的API了。

2. 编写Hadoop应用程序

2.1. 编写合并文本的应用程序

既然我们要使用hadoop与hdfs，那势必要启动hadoop服务器，这个是之前一项作业提到过的，配置好之后脚本启动就ok。

对于应用的程序，本次的任务是把某些特定文件的内容合并到一个文件merge.txt中，需要根据特殊的规则过滤掉不符合内容的文件，例如source3.abc。

然后为了批量上传文件到hdfs，我写了个上传文件的脚本：

```
package Merge_File_Demo.UploadFiles;

import org.apache.hadoop.conf.Configuration;
import org.apache.hadoop.fs.FileSystem;
import org.apache.hadoop.fs.Path;
import org.apache.hadoop.io.IOUtils;

import java.io.File;
import java.io.FileInputStream;
import java.io.IOException;
import java.io.InputStream;
import java.net.URI;

public class Upload {
    public static void main(String[] args) {
        // HDFS配置
        Configuration conf = new Configuration();
        conf.set("fs.defaultFS", "hdfs://localhost:9000");
        conf.set("fs.hdfs.impl", "org.apache.hadoop.hdfs.Distril

        // 本地文件目录
        String localDirPath = args[0];

        // HDFS目标路径
        String hdfsTargetPath = args[1];

        try {
            // 获取HDFS文件系统对象
            FileSystem fs = FileSystem.get(URI.create(conf.get('

            // 遍历本地目录并上传文件
            File localDir = new File(localDirPath);
            File[] files = localDir.listFiles();
            if (files != null) {
                for (File file : files) {
```

```
                    if (file.isFile()) {
                        // 创建HDFS路径对象
                        Path hdfsPath = new Path(hdfsTargetPath

                        // 打开本地文件输入流
                        InputStream in = new FileInputStream(fi

                        // 使用Hadoop的API将文件写入HDFS
                        fs.copyFromLocalFile(new Path(file.getAb

                        // 关闭输入流
                        IOUtils.closeStream(in);
                        System.out.println("File " + file.getNam
                    }
                }
            } else {
                System.out.println("No files found in the local
            }

            // 关闭文件系统连接
            fs.close();
        } catch (IOException | InterruptedException e) {
            e.printStackTrace();
        }
    }
}
```

大致意思就是命令行给参数，然后遍历指定的本地目录，把文件全部上传到hdfs的指定目录里面去。

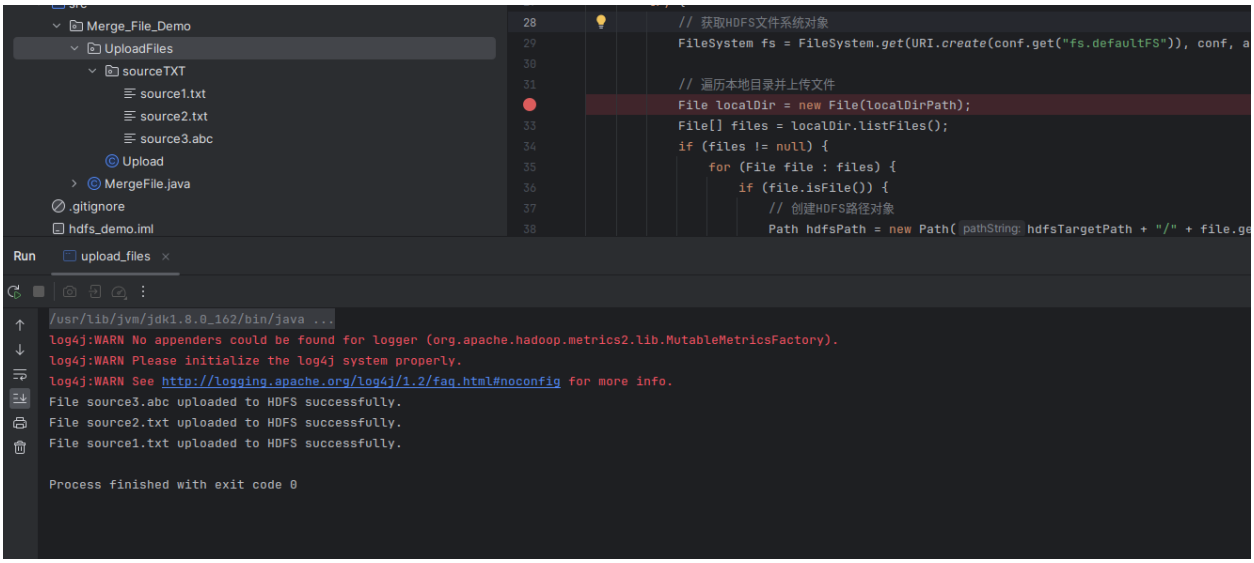

运行结果大概这样。

然后运行合并文件的应用程序，结果如下：

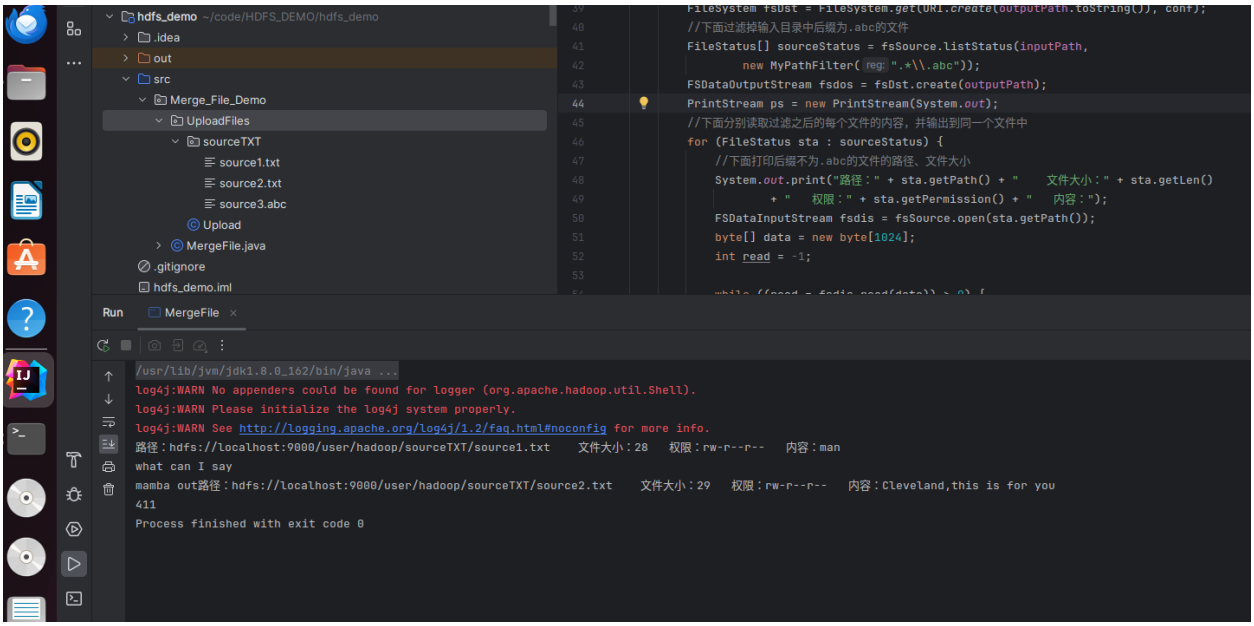

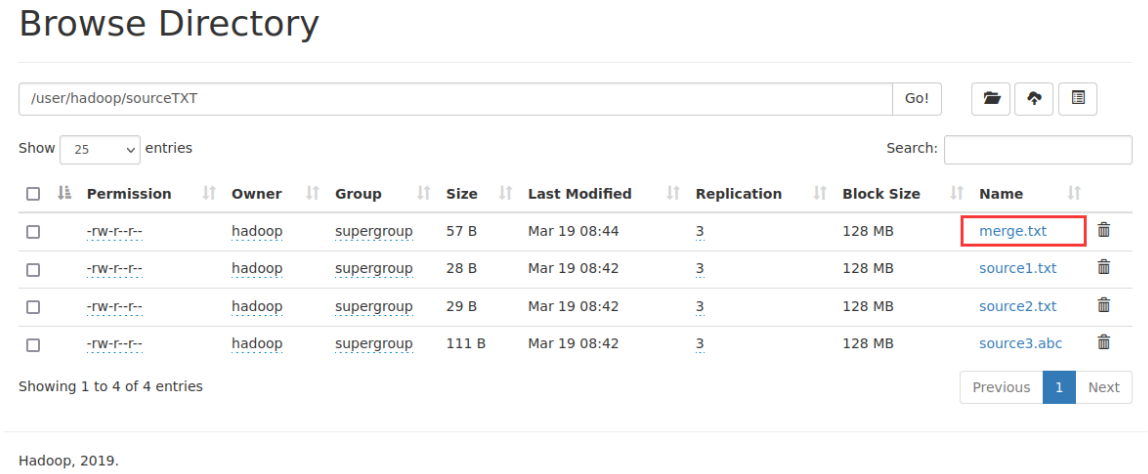

从web页面可以看到merge.txt已经生成了。

随后我们利用hdfs的get命令把merge.txt拉到本地来。结果如下：

可以看到确实只有source1和source2的内容，source3.abc被过滤了。

2.2. 应用程序打包

通过idea提供的build artifacts，将两个应用程序（一个用来上传文件，一个用来合并文件）打包放置到/usr/local/hadoop/myapp

随后清除一下之前在idea中执行的记录，把hadoop:localhost:9000/user/hadoop/sourceTXT下的文件全部清除，之后测试两个jar包。

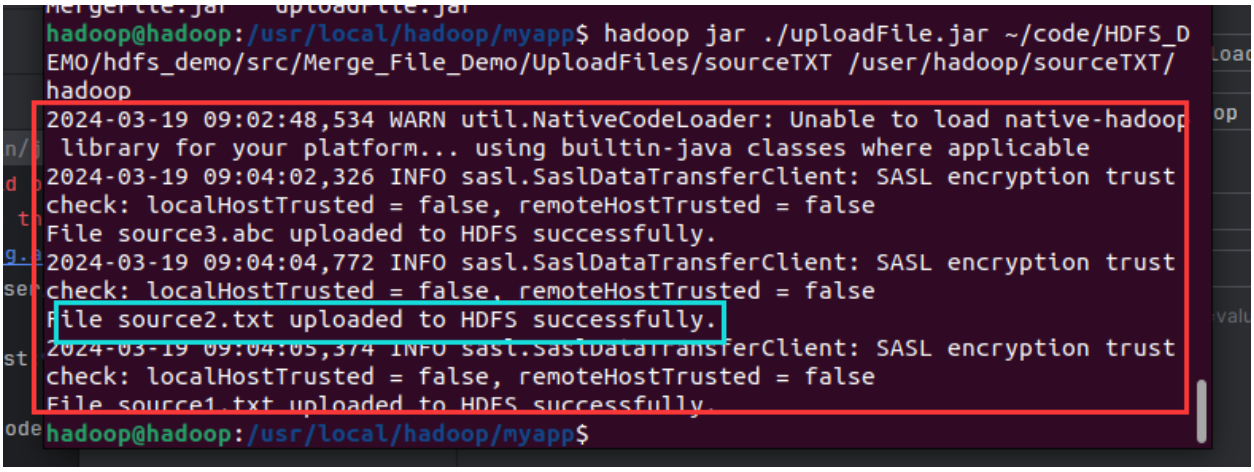

上传程序成功。

随后运行合并程序。

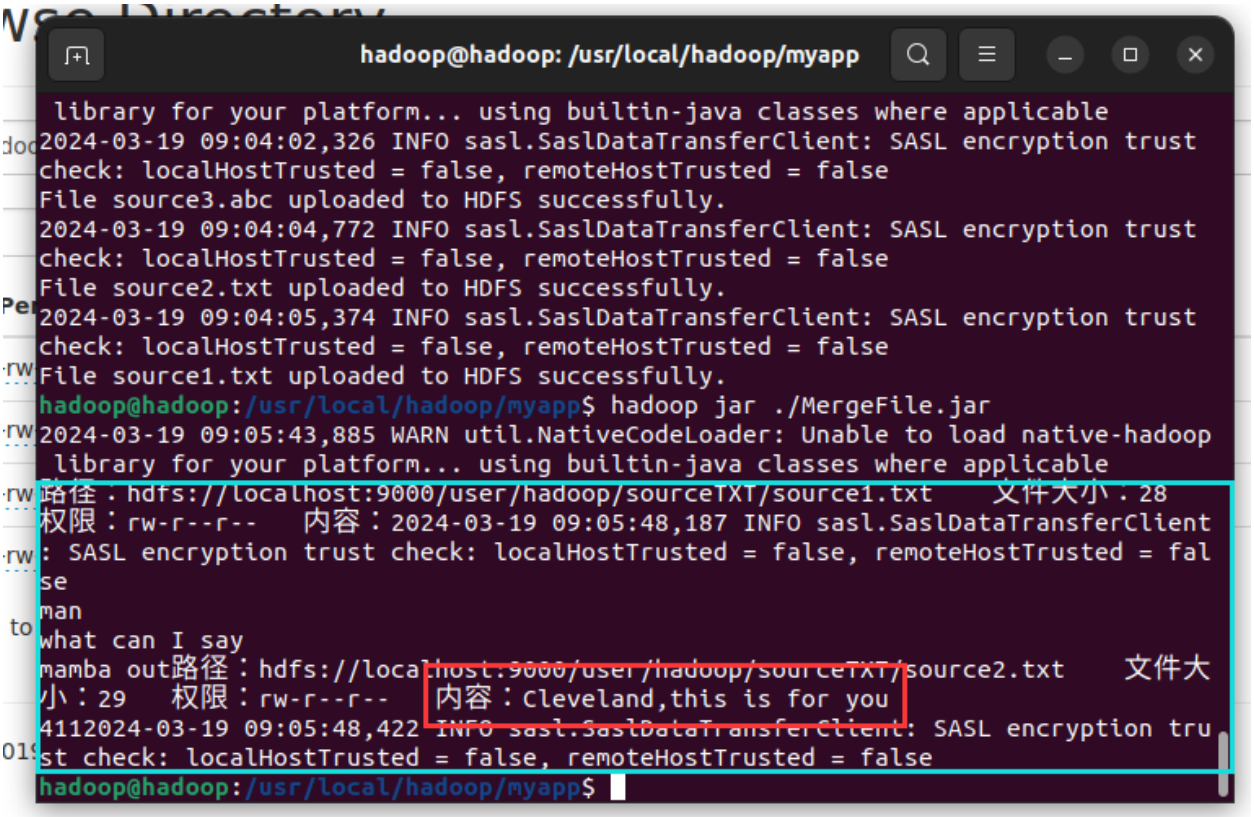

合并程序成功。

随后我们用hdfs dfs -cat捕获一下新出现的merge.txt

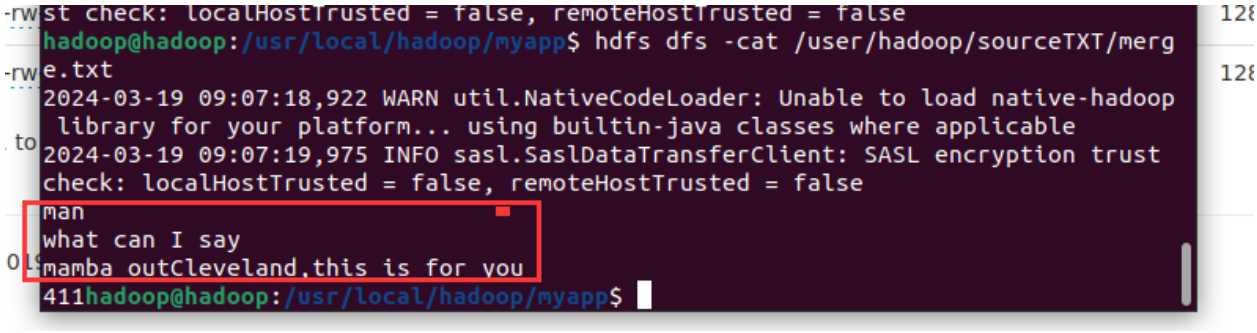

内容正确，两个应用程序均成功。