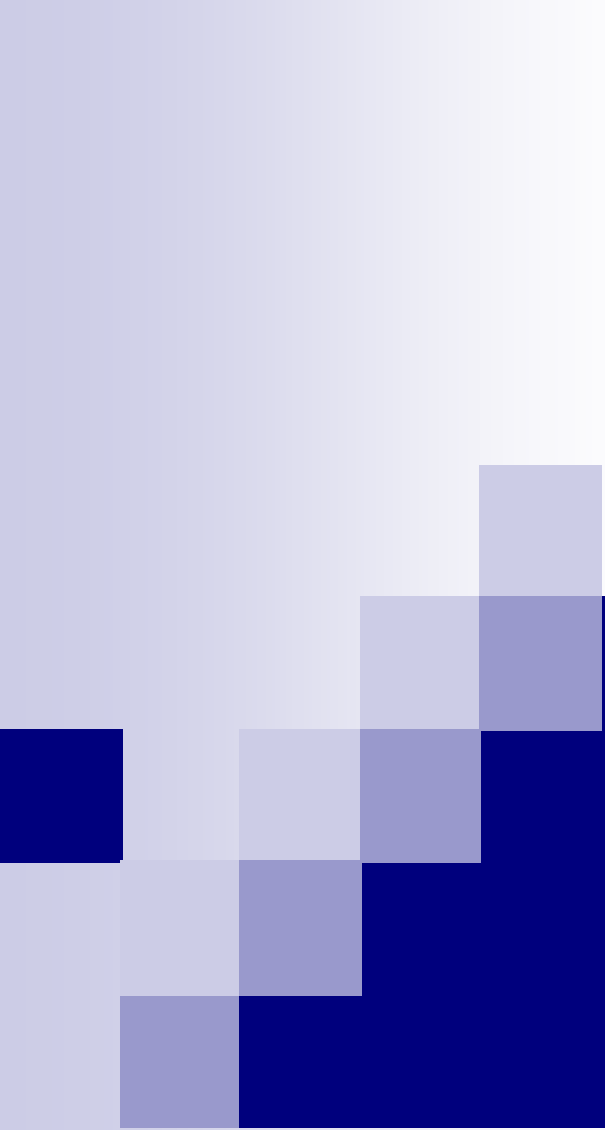


# 线性最小二乘

## ■ 内容

- 线性最小二乘法问题
- 解的存在性和唯一性
- 问题的敏感性和病态性
- 求解方法
  - 正规方程组法
  - 增广方程组法
  - 正交变换法
  - 奇异值分解法




# 线性最小二乘问题

# 曲线拟合问题

## ■ Motivation

- 发现数据的规律, “回归分析”
- 由于数据可能有误差, 逼近曲线不必通过所有点



## ■ 问题描述

- 数据点  $(t_i, y_i)$ ,  $(i=1, \dots, m)$ , 用函数  $f(t)$  来拟合
- 拟合要求:  $\sum_{i=1}^m [f(t_i) - y_i]^2$  最小, “**最小二乘**”
- 若  $f(t) = \sum_{j=1}^n \mathbf{x}_j \varphi_j(t)$ , 求系数  $\mathbf{x}_j$ , **线性最小二乘**

通常  $m > n$

- 多项式拟合  $f(t, \mathbf{x}) = x_1 + x_2 t + x_3 t^2 + \dots + x_n t^{n-1}$

**线性:** 函数  $f$  是参数向量  $\mathbf{x}$  的分量的线性函数

# 线性最小二乘 (Linear Least Squares)

## ■ 线性最小二乘问题的矩阵表述

$$\text{设 } \mathbf{b} = [y_1, \dots, y_m]^T, \quad \mathbf{x} = [x_1, \dots, x_m]^T$$

$$\mathbf{A} = \begin{bmatrix} \varphi_1(t_1) & \varphi_2(t_1) & \cdots & \varphi_n(t_1) \\ \varphi_1(t_2) & \varphi_2(t_2) & \cdots & \varphi_n(t_2) \\ \vdots & \vdots & \vdots & \vdots \\ \varphi_1(t_m) & \varphi_2(t_m) & \cdots & \varphi_n(t_m) \end{bmatrix}$$
$$f(t) \approx \sum_{j=1}^n x_j \varphi_j(t)$$
$$\sum_{i=1}^m [f(t_i) - y_i]^2 \text{ 最小}$$

$\mathbf{Ax} \cong \mathbf{b}$  求  $\mathbf{x}$ , 使  $\|\mathbf{b} - \mathbf{Ax}\|_2$  最小

解  $\mathbf{x}$  称为该问题的 **最小二乘解**,  $f(t) = \sum_{j=1}^n x_j \varphi_j(t)$


$\mathbf{A}$  是  $m \times n$  矩阵, 且  $m > n$ , 超定方程组, 即方程的个数多于未知数的个数

例 对 21个数据点的二次多项式拟合

二次多项式  $f(t, \mathbf{x}) = x_1 + x_2 t + x_3 t^2$

矩阵  $A$  是  $21 \times 3$

$$A\mathbf{x} = \begin{bmatrix} 1 & t_1 & t_1^2 \\ 1 & t_2 & t_2^2 \\ 1 & t_3 & t_3^2 \\ \vdots & \vdots & \vdots \\ 1 & t_{21} & t_{21}^2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \cong \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_{21} \end{bmatrix} = \mathbf{b}$$




这种矩阵称为范德蒙 (Vandermonde) 矩阵, 它的列 (或行) 是一些独立变量的顺序幂次.

求得的多项式是在所有二次多项式中对给定数据的**最佳拟合**, 即在所有的二次多项式中, 这个多项式与数据点的竖直距离的平方和最小.

# 线性最小二乘解的存在性和惟一性

- 线性最小二乘问题  $Ax \cong b$  的解的存在性是有保证的
- 线性最小二乘问题  $Ax \cong b$  的解惟一的充要条件是  $A$  列满秩, 即  $\text{rank}(A) = n$ .
- 如果  $\text{rank}(A) < n$ , 称  $A$  为秩亏损的. 相应的最小二乘问题的解存在, 但不惟一



# 线性最小二乘问题的敏感性和病态性

- $A$  是列满秩,  $A^T A$  非奇异,  $A$  的广义逆  $A^+ = (A^T A)^{-1} A^T$

- $m \times n$  阶列满秩矩阵的条件数为  $\text{cond}(A) = \|A\|_2 \cdot \|A^+\|_2$

- 非方阵的条件数度量了与秩亏损阵的接近程度

- 最小二乘解  $x$  关于  $b$  的扰动  $\Delta b$  的条件数不仅与  $\text{cond}(A)$  有关, 还与  $b$  和  $Ax$  的夹角  $\theta$  有关

$$\frac{\|\Delta x\|_2}{\|x\|_2} \leq \text{cond}(A) \cdot \frac{1}{\cos\theta} \cdot \frac{\|\Delta b\|_2}{\|b\|_2}$$

- 最小二乘解  $x$  关于矩阵  $A$  的扰动  $E$  的条件数不仅与  $\text{cond}(A)$  有关, 还与  $b$  和  $Ax$  的夹角  $\theta$  有关

$$\frac{\|\Delta x\|_2}{\|x\|_2} \lesssim ([\text{cond}(A)]^2 \tan\theta + \text{cond}(A)) \frac{\|E\|_2}{\|A\|_2}$$

**例** 测量员要测量在某个基准点上 3 个山头的高度. 首先从基准点观测, 测得高度分别为  $x_1 = 1237\text{ft}$ ,  $x_2 = 1914\text{ft}$ ,  $x_3 = 2417\text{ft}$ . (ft:英尺). 为进一步确认初始的测量数据, 测量员爬上第一座小山, 测得第二座小山相对于第一座小山的高度为  $x_2 - x_1 = 711\text{ft}$ , 第三座相对于第一座的高度为  $x_3 - x_1 = 1177\text{ft}$ . 最后, 测量员爬上第二座小山, 测得第三座小山相对于第二座小山的高度是  $x_3 - x_2 = 475\text{ft}$ . 这些测量值对应一个超定方程组

$$Ax = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ -1 & 1 & 0 \\ -1 & 0 & 1 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \cong \begin{bmatrix} 1237 \\ 1941 \\ 2417 \\ 711 \\ 1177 \\ 475 \end{bmatrix} = b,$$

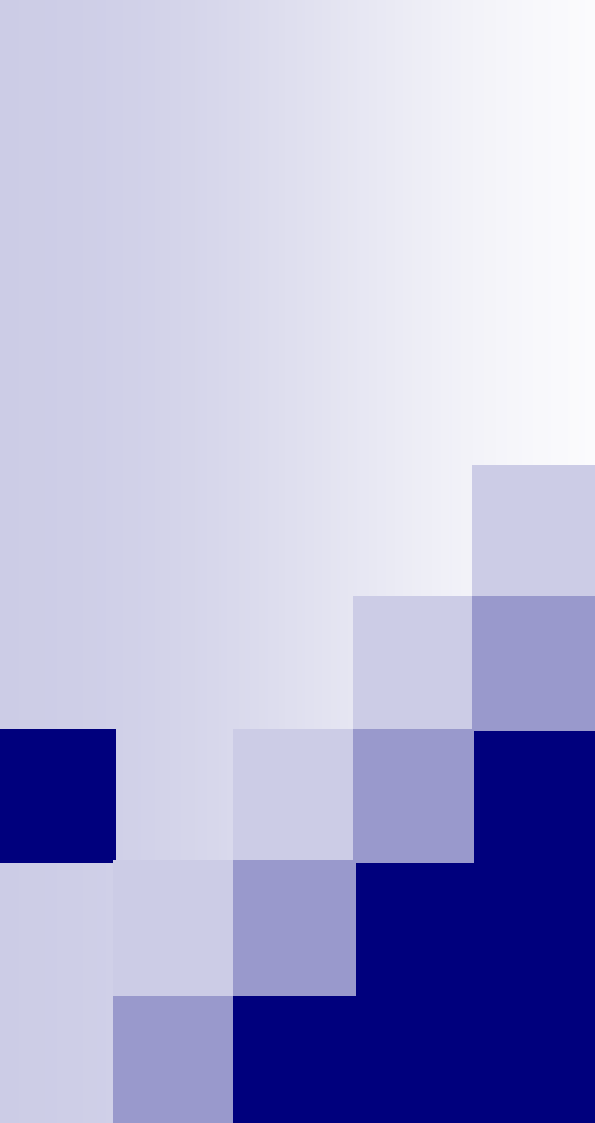
$$A^+ = (A^T A)^{-1} A^T = \frac{1}{4} \begin{bmatrix} 2 & 1 & 1 & -1 & -1 & 0 \\ 1 & 2 & 1 & 1 & 0 & -1 \\ 1 & 1 & 2 & 0 & 1 & 1 \end{bmatrix}$$

$$\|A\|_2 = 2, \|A^+\|_2 = 1, \text{cond}(A) = \|A\|_2 \cdot \|A^+\|_2 = 2.$$

$$\cos \theta = \frac{\|Ax\|_2}{\|b\|_2} = \frac{\|y\|_2}{\|b\|_2} \approx \frac{3640.8761}{3640.8809} \approx 0.99999868,$$

夹角大约为 0.001625, 由于条件数和角度  $\theta$  都非常小, 所以这个最小二乘问题是良态的.





# 线性最小二乘的求解

# 正规方程组法

目标是残差向量  $\mathbf{r} = \mathbf{b} - \mathbf{A}\mathbf{x}$  的欧几里得范数的平方取得最小值

目标函数是  $\phi: \mathbb{R}^n \rightarrow \mathbb{R}$ ,

$$\begin{aligned}\phi(\mathbf{x}) &= \|\mathbf{r}\|_2^2 = \mathbf{r}^T \mathbf{r} = (\mathbf{b} - \mathbf{A}\mathbf{x})^T (\mathbf{b} - \mathbf{A}\mathbf{x}) \\ &= \mathbf{b}^T \mathbf{b} - 2\mathbf{x}^T \mathbf{A}^T \mathbf{b} + \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x}\end{aligned}$$

取最小值的必要条件是  $\mathbf{x}$  点的梯度向量  $\nabla \phi(\mathbf{x})$  为零,  $\nabla \phi(\mathbf{x})$  的第  $i$  个分量为  $\partial \phi(\mathbf{x}) / \partial x_i$ ,


$$\mathbf{0} = \nabla \phi(\mathbf{x}) = 2\mathbf{A}^T \mathbf{A} \mathbf{x} - 2\mathbf{A}^T \mathbf{b}.$$

因此  $\phi$  的最小值点  $\mathbf{x}$  一定满足  $n \times n$  的对称线性方程组(正规方程组)

$$\mathbf{A}^T \mathbf{A} \mathbf{x} = \mathbf{A}^T \mathbf{b}$$

对于  $m > n$  的最小二乘问题,  $m$  维向量  $\mathbf{b}$  一般不属于  $\text{span}(\mathbf{A})$ , 子空间  $\text{span}(\mathbf{A})$  的维数最大为  $n$ . 当残差向量  $\mathbf{r} = \mathbf{b} - \mathbf{A}\mathbf{x}$  垂直于  $\text{span}(\mathbf{A})$  时, 向量  $\mathbf{y} = \mathbf{A}\mathbf{x} \in \text{span}(\mathbf{A})$  在欧几里得范数意义下是最接近  $\mathbf{b}$  的. 这样, 对于最小二乘解  $\mathbf{x}$ , 残差向量  $\mathbf{r} = \mathbf{b} - \mathbf{A}\mathbf{x}$  一定垂直于  $\mathbf{A}$  的各列, 因此

$$\mathbf{0} = \mathbf{A}^T \mathbf{r} = \mathbf{A}^T (\mathbf{b} - \mathbf{A}\mathbf{x}), \quad \mathbf{A}^T \mathbf{A}\mathbf{x} = \mathbf{A}^T \mathbf{b}.$$



例

$$\mathbf{Ax} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ -1 & 1 & 0 \\ -1 & 0 & 1 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \cong \begin{bmatrix} 1237 \\ 1941 \\ 2417 \\ 711 \\ 1177 \\ 475 \end{bmatrix} = \mathbf{b}$$

正规方程组为

$$\mathbf{A}^T \mathbf{Ax} = \begin{bmatrix} 3 & -1 & -1 \\ -1 & 3 & -1 \\ -1 & -1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} -651 \\ 2177 \\ 4069 \end{bmatrix} = \mathbf{A}^T \mathbf{b}.$$

利用楚列斯基分解得到

$$\mathbf{A}^T \mathbf{A} = \mathbf{LL}^T,$$

其中  $\mathbf{L}$  是下三角阵, 求解  $\mathbf{Ly} = \mathbf{A}^T \mathbf{b}$  和  $\mathbf{L}^T \mathbf{x} = \mathbf{y}$  得到

$\mathbf{x}^T = [1236, 1943, 2416]^T$ , 对应的残差平方和的最小值  $\|\mathbf{r}\|_2^2 = 35$ .

问题转换的过程: 长方阵  $\rightarrow$  方阵  $\rightarrow$  三角阵.

理论上合理的转换方法数值上不一定可靠. 理论上, 由正规方程组可以得到线性最小二乘问题的精确解, 但实际上这种方法得到的解往往令人失望.

- 形成矩阵 $\mathbf{A}^T \mathbf{A}$ 和右端向量 $\mathbf{A}^T \mathbf{b}$ 时会产生信息丢失. 例如,

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ \varepsilon & 0 \\ 0 & \varepsilon \end{bmatrix}, \text{ 其中 } 0 < \varepsilon < \sqrt{\varepsilon_{\text{mach}}}.$$

利用浮点计算,  $\mathbf{A}^T \mathbf{A} = \begin{bmatrix} 1 + \varepsilon^2 & 1 \\ 1 & 1 + \varepsilon^2 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ , 这是一个奇异矩阵.

- 矩阵 $\mathbf{A}^T \mathbf{A}$ 的条件数是原矩阵 $\mathbf{A}$ 条件数的平方,

$$\text{cond}(\mathbf{A}^T \mathbf{A}) = [\text{cond}(\mathbf{A})]^2,$$

这个条件数决定了正规方程组解的敏感性. 即使在拟合良好, 并且残差也较小的情况下, 正规方程组也会出现条件数平方效应, 这就使得计算解的敏感性比原来的最小二乘问题更强. 在这个意义上**正规方程组解法是不稳定的**.

# 增广方程组法

令残差向量  $r$  与  $A$  的各列正交, 得到方程组

$$\begin{aligned} r + Ax &= b, \\ A^T r &= 0, \end{aligned}$$

写成矩阵形式, 称为  $(m + n) \times (m + n)$  增广方程组

$$\begin{bmatrix} I & A \\ A^T & 0 \end{bmatrix} \begin{bmatrix} r \\ x \end{bmatrix} = \begin{bmatrix} b \\ 0 \end{bmatrix}.$$

由这个方程既可得到所需的解  $x$ , 又可得到这个解的残差向量  $r$ .

- 增广方程组对称但不正定, 而且方程组变大, 尽管可以利用增广矩阵的特殊结构(稀疏性)
- 直接选主元会再次产生正规方程组, 数值稳定性很差. 可以采用其他的选主元策略, 以保证数值稳定.

# 上三角最小二乘问题的求解

$$\begin{bmatrix} \mathbf{R} \\ \mathbf{0} \end{bmatrix} \mathbf{x} \cong \begin{bmatrix} \mathbf{c}_1 \\ \mathbf{c}_2 \end{bmatrix}, \quad \mathbf{R} \text{ 是 } n \times n \text{ 上三角阵}$$

$$\|\mathbf{r}\|_2^2 = \|\mathbf{c}_1 - \mathbf{R}\mathbf{x}\|_2^2 + \|\mathbf{c}_2\|_2^2.$$

式中第二项与  $\mathbf{x}$  无关, 可以选择使第一项为零的  $\mathbf{x}$ , 使  $\|\mathbf{r}\|_2^2$  取极小值. 此时,  $\mathbf{x}$  应满足上三角方程组

$$\mathbf{R}\mathbf{x} = \mathbf{c}_1,$$

可以用回代法求解出  $\mathbf{x}$ . 这样就得到了最小二乘解  $\mathbf{x}$  及  $\|\mathbf{r}\|_2^2 = \|\mathbf{c}_2\|_2^2$ .

# 正交变换法

用高斯消去法将矩阵约化成三角阵的形式并不合适, 因为这种变换并不能保证欧几里得范数不变, 不能保持最小二乘解不变.

需要一种能保持欧几里得范数不变的线性变换.

- 如果一个实方阵  $Q$  的各列正交, 即  $Q^T Q = I$ , 则称  $Q$  为**正交阵**.
- 正交变换不改变向量的欧几里得范数:

$$\|Qv\|_2^2 = (Qv)^T Qv = v^T Q^T Qv = v^T v = \|v\|_2^2$$

正交阵可以对向量作各种方式的变换, 像旋转、反射, 但它并不改变向量的欧几里得长度.

- 若将线性最小二乘方程组两端同时乘上正交阵, 最小二乘解并不改变.



# QR 分解

- $m \times n$ , 且  $m > n$  的矩阵  $A$  的QR 分解:

$$A = Q \begin{bmatrix} R \\ 0 \end{bmatrix}$$

其中  $Q$  是  $m \times m$  正交矩阵,  $R$  是  $n \times n$  上三角阵.

- QR分解将线性最小二乘问题  $Ax \cong b$  转化成上三角最小二乘问题,但解不变。

设变换后的右端向量为  $Q^T b = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix}$ ,

$$\|r\|_2^2 = \|b - Ax\|_2^2 = \left\| b - Q \begin{bmatrix} R \\ 0 \end{bmatrix} x \right\|_2^2 = \left\| Q^T b - \begin{bmatrix} R \\ 0 \end{bmatrix} x \right\|_2^2 = \|c_1 - Rx\|_2^2 + \|c_2\|_2^2$$

其中  $c_1$  是  $n$  维向量. 解  $x$  满足  $n \times n$  三角线性方程组  $Rx = c_1$

最小残差的范数  $\|r\|_2 = \|c_2\|_2$ .

# 矩阵奇异值/奇异向量

## ■ $m \times n$ 实矩阵 $A$ 的奇异值

(可看成非方阵的“特征值”)

$$\begin{cases} Av = \sigma u \\ A^T u = \sigma v \end{cases} \quad \begin{array}{l} \text{非负实数 } \sigma \text{ 为奇异值 (singular value)} \\ \text{非零向量 } u, v \text{ 为左/右奇异向量 (singular vector)} \end{array}$$
$$u^T A = \sigma v^T$$

奇异向量对有无穷多个. 一般取单位化的向量:  $\|u\|_2 = \|v\|_2 = 1$

□ 设  $m \geq n$ , 矩阵  $A$  可以分解为  $A = U \Sigma V^T$ ,  $U, V$  为正交阵,  $\Sigma$  为对角阵, 其对角元  $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_n \geq 0$ .

→  $AV = U\Sigma$ ,  $Av_k = \sigma_k u_k$ ,  $k = 1, \dots, n$

同时  $A^T = V\Sigma^T U^T$ ,  $A^T U = V\Sigma^T$ ,  $A^T u_k = \sigma_k v_k$

$$\Sigma = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix}$$

$u_k/v_k$  为左/右奇异向量(能找到  $n$  对), 且  $\{u_k\}$  和  $\{v_k\}$  各自两两正交

□ 当  $A$  为实对称半正定阵时, 奇异值分解 = 特征值分解

## 例 奇异值分解

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \\ 10 & 11 & 12 \end{bmatrix} \text{的奇异值分解为}$$

$$U\Sigma V^T = \begin{bmatrix} 0.141 & 0.825 & -0.420 & -0.351 \\ 0.344 & 0.426 & 0.298 & 0.782 \\ 0.547 & 0.028 & 0.664 & -0.509 \\ 0.750 & -0.371 & -0.542 & 0.079 \end{bmatrix} \begin{bmatrix} 25.5 & 0 & 0 \\ 0 & 1.29 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0.504 & 0.574 & 0.644 \\ -0.761 & -0.057 & 0.646 \\ 0.408 & -0.816 & 0.408 \end{bmatrix}$$

$$\sigma_1 = 25.5, \sigma_2 = 1.29, \sigma_3 = 0.$$

有个奇异值为零, 说明矩阵是秩亏损的.

矩阵的秩等于其非零奇异值的个数, 矩阵A的秩为 2.

# 奇异值分解(SVD)法

设  $A$  是  $m \times n$  满秩矩阵, 且  $\text{rank}(A) = n$ ,  $A$  的 SVD 为

$$A = U\Sigma V^T = [U_1 \quad U_2] \begin{bmatrix} \Sigma \\ 0 \end{bmatrix} V^T = U_1 \Sigma_1 V^T,$$

其中  $U_1$  是  $m \times n$  矩阵,  $\Sigma_1$  是  $n \times n$  非奇异矩阵.

最小二乘问题  $Ax \cong b$  的解满足:  $U_1 \Sigma_1 V^T x \cong b$

$$x = V \Sigma_1^{-1} U_1^T b = \sum_i \frac{u_i^T b}{\sigma_i} v_i$$

其证明只需将  $A$  的 SVD 代入正规方程.

# 方法间的比较

- **正规方程组法**易于实现, 只需要矩阵乘法和楚列斯基分解, 产生的解的相对误差与  $[\text{cond}(\mathbf{A})^2]$  成比例. 当**问题充分良态**时,正规方程组方法可提供充分精确的解。
- 对于接近方阵即  $m \approx n$  的问题, 正规方程组方法和正交变换法所需的工作量大约相同. 但对于高度超定即  $m \gg n$  的问题,**正交变换法**的工作量大约为正规方程组方法的两倍, 但精度更高, 应用更广泛。
- **SVD**计算量大, 具有极强稳健性和可靠性, 在**问题特别敏感**的情形才使用。

# 矩阵的QR分解

- 豪斯霍尔德(Householder)变换 (初等反射)
- 吉文斯(Givens)变换 (平面旋转)
- 格拉姆 - 施密特(Gram-Schmidt)正交化

## 格拉姆－施密特(Gram-Schmidt)正交化

$$\alpha_1, \alpha_2, \dots, \alpha_n \text{ 线性无关} \quad \beta_1 = \alpha_1, \varepsilon_1 = \frac{\beta_1}{|\beta_1|},$$

$$\beta_2 = \alpha_2 - \langle \alpha_2, \varepsilon_1 \rangle \varepsilon_1, \varepsilon_2 = \frac{\beta_2}{|\beta_2|},$$

$\{\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n\}$  两两正交,

.....

且是单位向量。

$$\beta_n = \alpha_n - \langle \alpha_n, \varepsilon_1 \rangle \varepsilon_1 - \dots - \langle \alpha_n, \varepsilon_{n-1} \rangle \varepsilon_{n-1}, \varepsilon_n = \frac{\beta_n}{|\beta_n|}$$


$$\begin{cases} \alpha_1 &= \beta_1 = |\beta_1| \varepsilon_1, \\ \alpha_2 &= \langle \alpha_2, \varepsilon_1 \rangle \varepsilon_1 + \beta_2 = \langle \alpha_2, \varepsilon_1 \rangle \varepsilon_1 + |\beta_2| \varepsilon_2, \\ &\vdots \\ \alpha_n &= \langle \alpha_n, \varepsilon_1 \rangle \varepsilon_1 + \dots + \langle \alpha_n, \varepsilon_{n-1} \rangle \varepsilon_{n-1} + \beta_n \\ &= \langle \alpha_n, \varepsilon_1 \rangle \varepsilon_1 + \dots + \langle \alpha_n, \varepsilon_{n-1} \rangle \varepsilon_{n-1} + |\beta_n| \varepsilon_n. \end{cases}$$

$$[\alpha_1 \quad \alpha_2 \quad \cdots \quad \alpha_n] = [\varepsilon_1 \quad \varepsilon_2 \quad \cdots \quad \varepsilon_n] R \quad R = \begin{bmatrix} |\beta_1| & \langle \alpha_2, \varepsilon_1 \rangle & \cdots & \langle \alpha_n, \varepsilon_1 \rangle \\ 0 & |\beta_2| & \cdots & \langle \alpha_n, \varepsilon_2 \rangle \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & \langle \alpha_n, \varepsilon_{n-1} \rangle \\ 0 & 0 & \cdots & |\beta_n| \end{bmatrix}$$

# Householder变换

## ■ 矩阵的正交三角化

- 高斯消去过程?
- 可用正交阵来乘吗?
- 是矩阵特征值计算、  
曲线拟合等解法的基础



## ■ Householder矩阵

- **定义**  $w \in \mathbb{R}^n$  且  $w^T w = 1$ , 称  $H(w) = I - 2ww^T$  为 Householder **矩阵** (初等反射阵)

- $H(w) = H(-w)$
- $H$  为对称阵、正交阵  $H =$
- $Hx$  实现 Householder 变换

$$H = \begin{bmatrix} 1-2w_1^2 & -2w_1w_2 & \cdots & -2w_1w_n \\ -2w_2w_1 & 1-2w_2^2 & \cdots & -2w_2w_n \\ \vdots & \vdots & \cdots & \vdots \\ -2w_nw_1 & -2w_nw_2 & \cdots & 1-2w_n^2 \end{bmatrix}$$



# Householder变换

## ■ Householder变换的几何意义


□  $Hx$ : 以 $w$ 为法向画出超平面 $S$

$$Hx = (I - 2ww^T)x = x - 2ww^Tx$$

$$ww^Tx = (w^Tx)w = v \xrightarrow{\text{绿色箭头}} Hx = x - 2v$$

□  $Hx$ 为 $x$ 关于平面 $S$ 的镜像 (初等反射变换)

□  $Hx$ 与 $x$ 的2-范数相等, 属于正交变换



- **Th5.18** 设 $x, y \in \mathbb{R}^n, x \neq y, \|x\|_2 = \|y\|_2$ , 则存在Householder矩阵 $H$ , 使 $Hx = y$

几何的启示:  $v = x - y, w = v/\|v\|_2$ , 构造矩阵 $H$

- **Th5.19** 可将定理5.18中的 $y$ 设为  $\begin{bmatrix} \pm\|x\|_2 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$  这样就用正交变换实现“消元”!  
取 $y = -\sigma e_1, \sigma = \text{sign}(x_1)\|x\|_2$  较好  
构造 $H$ 时,  $v = x + \sigma e_1$

# Householder变换

$$\mathbf{x} \xrightarrow{H} -\sigma \mathbf{e}_1 \quad \begin{bmatrix} * \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$
$$\sigma = \text{sign}(x_1) \|\mathbf{x}\|_2$$

## ■ 正交变换实现消元

- 对向量 $\mathbf{x}$ 做Householder变换, 结果 $-\sigma \mathbf{e}_1$ 中的负号是为了数值稳定

例: 确定一个Householder变换, 对向量实现消元操作

$$\mathbf{a} = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix} \longrightarrow \begin{bmatrix} * \\ 0 \\ 0 \end{bmatrix}$$

解:  $\sigma = \text{sign}(a_1) \|\mathbf{a}\|_2 = 3$ , 构造  $\mathbf{v} = \mathbf{a} + \sigma \mathbf{e}_1 = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix} + \begin{bmatrix} 3 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 5 \\ 1 \\ 2 \end{bmatrix}$

取  $\mathbf{w} = \mathbf{v} / \|\mathbf{v}\|_2$ , 则实现变换的矩阵为  $H = I - 2\mathbf{w}\mathbf{w}^T$

验证:  $H\mathbf{a} = \mathbf{a} - 2(\mathbf{w}^T \mathbf{a})\mathbf{w} = \mathbf{a} - 2 \frac{\mathbf{v}^T \mathbf{a}}{\mathbf{v}^T \mathbf{v}} \mathbf{v} = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix} - 2 \times \frac{15}{30} \times \begin{bmatrix} 5 \\ 1 \\ 2 \end{bmatrix} = \begin{bmatrix} -3 \\ 0 \\ 0 \end{bmatrix}$

用 $\mathbf{v}$ 或 $\mathbf{w}$ 计算 $H\mathbf{x}$ 时只算向量内积


# 矩阵的QR分解

## ■ 用Householder变换实现正交三角化

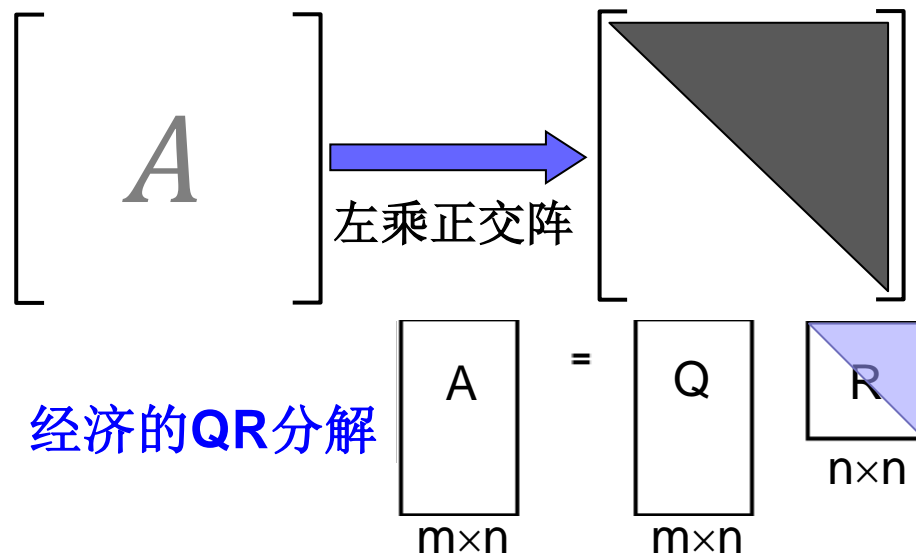
□  $H_k \cdots H_2 H_1 A = R$

$A \in \mathbb{R}^{m \times n}$ 不一定是方阵,  
上三角阵 $R$ 也同样

$m > n$ 的情况:



$m = n$ 的情况:



□  $A = H_1 H_2 \cdots H_k R = QR$ , 其中 $Q$ 为正交阵, 称为**QR分解**

**Th5.20** 对任意实矩阵 $A$ , 一定存在QR分解;

若 $A$ 为非奇异方阵, 且要求 $R$ 的对角元都 $>0$ , 此分解唯一.

# 矩阵的QR分解

■ 怎么实现:  $H_k \cdots H_2 H_1 A = R$

□ 设  $A \in \mathbb{R}^{m \times n}$ ,  $m \geq n$ ,  $A = [a_1, a_2, \dots, a_n]$ , 其中  $a_j$  为  $m$  维向量

构造  $m$  阶反射阵  $H_1$

消  $A$  的第1列:

$$A^{(2)} = H_1 A = \begin{bmatrix} -\sigma_1 & a_{12}^{(2)} & \cdots & a_{1n}^{(2)} \\ 0 & a_{22}^{(2)} & \cdots & a_{2n}^{(2)} \\ \vdots & \vdots & & \vdots \\ 0 & a_{m2}^{(2)} & \cdots & a_{mn}^{(2)} \end{bmatrix} = \begin{bmatrix} -\sigma_1 & | & & | \\ 0 & H_1 a_2 & \cdots & H_1 a_n \\ \vdots & | & & | \\ 0 & | & & | \end{bmatrix}$$

用  $H_2$  对  $A^{(2)}$  第2列消元, 同时不影响第1列

$$\text{令 } H_2 = \begin{bmatrix} 1 & \mathbf{0}^T \\ \mathbf{0} & H'_2 \end{bmatrix}$$

$$H_2 A^{(2)} = \begin{bmatrix} -\sigma_1 & r_1^T \\ \mathbf{0} & H'_2 A'^{(2)} \end{bmatrix}$$

$$\text{记 } A^{(2)} = \begin{bmatrix} -\sigma_1 & r_1^T \\ \mathbf{0} & A'^{(2)} \end{bmatrix}$$

构造反射阵  $H'_2$

$$= \begin{bmatrix} -\sigma_1 & r_1^T \\ 0 & -\sigma_2 & | & & | \\ 0 & 0 & H'_2 a'_2 & \cdots & H'_2 a'_{n-1} \\ \vdots & \vdots & | & & | \\ 0 & 0 & | & & | \end{bmatrix}$$

$H_2$  也是Householder阵(其向量  $v$  的第一个分量为0). 后续  $H_j$  可类似构造

### 算法5.3: 基于Householder变换的矩阵正交三角化 (设 $m \geq n$ )

输入:  $A = [a_1, a_2, \dots, a_n]$ ; 输出:  $A; v_1, v_2, \dots, v_n$ .

For  $k=1, 2, \dots, n$

$\sigma_k := \text{sign}(a_{kk}) \sqrt{\sum_{j=k}^m a_{jk}^2}$ ;      {下三角部分第 $k$ 列的2-范数}

If  $\sigma_k = a_{kk}$  then      {第 $k$ 列对角线下方已经全为0}

Continue with next  $k$ ;

End

$v_k := [0, \dots, 0, a_{kk}, \dots, a_{mk}]^T + \sigma_k e_k$ ;      {构造 $H_k$ 的向量}

$\beta_k := v_k^T v_k$ ;

For  $j=k, k+1, \dots, n$       {对剩余各列作Householder变换}

$\gamma_j := v_k^T a_j$ ;

$a_j := a_j - (2\gamma_j/\beta_k)v_k$ ;      {  $H_k a_j^{(k)} = a_j^{(k)} - 2(v_k^T a_j^{(k)}/v_k^T v_k)v_k$  }

End

End

- 算法执行完,  $A$ 变成 $R$ , 得到构造 $H_1, H_2, \dots, H_k$ 所需的 $v$ 向量
- 总乘法次数:  $(2n+1) \cdot m + (2n-1) \cdot m + \dots + 3m \approx mn^2$
- 没有生成 $Q$ 矩阵. 如果生成, 则计算量为 $O(mn^2)$


Matlab:  $[Q, R] = \text{qr}(A)$ ;  $R = \text{qr}(A)$

# Givens旋转变换

## ■ 二维平面旋转变换

- 将向量 $x$ 顺时针旋转 $\theta$ 角度后得到 $y$

$$y = \begin{bmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{bmatrix} x$$



- 二阶Givens矩阵为:  $G = \begin{bmatrix} c & s \\ -s & c \end{bmatrix}$ , 其中  $c = \cos\theta, s = \sin\theta$

- $G$ 是2x2的正交阵, 实施平面旋转(称为Givens旋转)

- 实现消元: 选 $c$ 和 $s$ 值可使  $G \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} \alpha \\ 0 \end{bmatrix}$ ,  $c = \frac{x_1}{\alpha}, s = \frac{x_2}{\alpha}$

## ■ n阶Givens旋转阵

将2阶Givens阵  
嵌入n阶单位阵:

$G$ 仍是正交阵

$$\begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & c & 0 & s & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & -s & 0 & c & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix} = \begin{bmatrix} x_1 \\ \alpha \\ x_3 \\ 0 \\ x_5 \end{bmatrix}$$

$$c = \frac{x_1}{\alpha}$$

$$s = \frac{x_4}{\alpha}$$

# Givens旋转变换

**例:** 用Givens旋转变换来消元

解: 先针对第1, 3分量构造二阶旋转矩阵,

$$G'_1 = \begin{bmatrix} c_1 & s_1 \\ -s_1 & c_1 \end{bmatrix} \quad c_1 = \frac{2}{\sqrt{2^2 + 1}} = 2/\sqrt{5}, \quad s_1 = 1/\sqrt{5}$$

$$a = \begin{bmatrix} 2 \\ 0 \\ 1 \\ 2 \end{bmatrix} \longrightarrow \begin{bmatrix} * \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

则:  $G_1 a = \begin{bmatrix} c_1 & 0 & s_1 & 0 \\ 0 & 1 & 0 & 0 \\ -s_1 & 0 & c_1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 0 \\ 1 \\ 2 \end{bmatrix} = \begin{bmatrix} \sqrt{5} \\ 0 \\ 0 \\ 2 \end{bmatrix}$  接着对第1, 4分量旋转

求出  $c_2 = \sqrt{5}/3, s_2 = 2/3$ ,  $G_2 G_1 a = \begin{bmatrix} c_2 & 0 & 0 & s_2 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ -s_2 & 0 & 0 & c_2 \end{bmatrix} \begin{bmatrix} \sqrt{5} \\ 0 \\ 0 \\ 2 \end{bmatrix} = \begin{bmatrix} 3 \\ 0 \\ 0 \\ 0 \end{bmatrix}$

- 每个Givens旋转用参数c, s刻画
- 每次旋转仅影响向量两个元素, 仅影响矩阵的两行
- 可实现矩阵的QR分解, 适合于稀疏矩阵

# 线性最小二乘

例：一组数据如下表，用适当的函数对它们进行拟合

|               |        |        |        |        |        |
|---------------|--------|--------|--------|--------|--------|
| $t_i$         | 1.00   | 1.25   | 1.50   | 1.75   | 2.00   |
| $y_i$         | 5.10   | 5.79   | 6.53   | 7.45   | 8.46   |
| $\tilde{y}_i$ | 1.6292 | 1.7561 | 1.8764 | 2.0082 | 2.1353 |

解：在直角坐标系里绘出这些数据点，根据其分布趋势，采用指数函数来描述： $y \approx x_1 e^{x_2 t}$

不能直接用线性最小二乘，需做变换  $\ln y \approx \ln x_1 + x_2 t$

$$\tilde{y} = \tilde{x}_1 + x_2 t$$

$$A = \begin{bmatrix} 1 & 1.00 \\ 1 & 1.25 \\ 1 & 1.5 \\ 1 & 1.75 \\ 1 & 2.00 \end{bmatrix}, \quad b = \begin{bmatrix} 1.6292 \\ 1.7561 \\ 1.8764 \\ 2.0082 \\ 2.1353 \end{bmatrix}$$

要解  $A^T A x = A^T b$ ，即 解得：

$$\begin{bmatrix} 5 & 7.5 \\ 7.5 & 11.875 \end{bmatrix} \begin{bmatrix} \tilde{x}_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 9.4052 \\ 14.4239 \end{bmatrix} \quad \begin{bmatrix} \tilde{x}_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.1225 \\ 0.5057 \end{bmatrix}$$

$$\longrightarrow x_1 = e^{\tilde{x}_1} = 3.0725$$

最后的解为  $f(t) = 3.0725 e^{0.5057t}$



# 线性最小二乘

解  $Ax \cong b$

$$A = \begin{bmatrix} 1 & 1.00 \\ 1 & 1.25 \\ 1 & 1.5 \\ 1 & 1.75 \\ 1 & 2.00 \end{bmatrix}, \quad b = \begin{bmatrix} 1.6292 \\ 1.7561 \\ 1.8764 \\ 2.0082 \\ 2.1353 \end{bmatrix}$$

$$\tilde{y} = \tilde{x}_1 + x_2 t$$

用Householder变换对A作正交三角化

$\sigma_1 = \sqrt{5}$  第一个变换用的  $v_1 = \begin{bmatrix} 1+\sqrt{5} \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$ , 则  $\begin{bmatrix} -2.236 & -3.354 \\ 0 & -0.095 \\ 0 & 0.155 \\ 0 & 0.405 \\ 0 & 0.655 \end{bmatrix} x \cong \begin{bmatrix} -4.206 \\ -0.047 \\ 0.073 \\ 0.205 \\ 0.332 \end{bmatrix}$

再做第二个变换得  $\begin{bmatrix} -2.236 & -3.354 \\ 0 & 0.791 \\ 0 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} x \cong \begin{bmatrix} -4.206 \\ 0.400 \\ -0.005 \\ 0.001 \\ 0.002 \end{bmatrix}$

解得:

$$\begin{bmatrix} \tilde{x}_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.1225 \\ 0.5057 \end{bmatrix}$$

# 线性最小二乘

## ■ Matlab命令

□ 线性最小二乘问题  $Ax \cong b$ ,  $A$  是  $m \times n$  矩阵,  $m > n$

>>  $x = A \setminus b$

□ 用不超过  $n$  次的多项式拟合离散点  $(x_i, y_i)$

>>  $p = \text{polyfit}(x, y, n)$

拟合多项式的系数存于向量  $p$ , 相关命令还有  $\text{polyval}$



# 矩阵奇异值分解

# 矩阵奇异值/奇异向量

## ■ $m \times n$ 实矩阵 $A$ 的奇异值

(可看成非方阵的“特征值”)

$$\begin{cases} Av = \sigma u \\ A^T u = \sigma v \end{cases} \quad \begin{array}{l} \text{非负实数 } \sigma \text{ 为奇异值 (singular value)} \\ \text{非零向量 } u, v \text{ 为左/右奇异向量 (singular vector)} \end{array}$$
$$u^T A = \sigma v^T$$

奇异向量对有无穷多个. 一般考虑单位化的:  $\|u\|_2 = \|v\|_2 = 1$

□ **Th5.23** 设  $m \geq n$ , 矩阵  $A$  可以分解为  $A = U \Sigma V^T$ ,  $U, V$  为正交阵,  $\Sigma$  为对角阵, 其对角元  $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_n \geq 0$ .

→  $AV = U\Sigma$ ,  $Av_k = \sigma_k u_k$ ,  $k = 1, \dots, n$        $\Sigma = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix}$

同时  $A^T = V\Sigma^T U^T$ ,  $A^T U = V\Sigma^T$ ,  $A^T u_k = \sigma_k v_k$

$u_k/v_k$  为左/右奇异向量(能找到  $n$  对), 且  $\{u_k\}$  和  $\{v_k\}$  各自两两正交

□ 当  $A$  为实对称半正定阵时, 奇异值分解 = 特征值分解

# 奇异值分解(SVD)

## ■ Th5.23 (奇异值分解定理)

“线性代数领域的瑞士军刀”

矩阵 $A$ 可以分解为 $A = U \Sigma V^T$ ,  $U, V$ 为正交阵,  $\Sigma$ 为对角阵, 其对角元 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0$ .

□ 只需证明 $m \geq n$ 的情况

思路:  $A^T A = \underset{n \times n}{V \Sigma^T \Sigma V^T} = V \begin{bmatrix} \sigma_1^2 & & \\ & \ddots & \\ & & \sigma_n^2 \end{bmatrix} V^T$

$A^T A$ 对称半正定, 设非零特征值为  $\sigma_1^2, \sigma_2^2, \dots, \sigma_r^2$  形成对角阵  $\Sigma_r^2$  (不妨设  $r < n$ )

$$A^T A = \underset{\text{(正交阵)}}{[V_1 \ V_2]} \begin{bmatrix} \Sigma_r^2 & O \\ O & O \end{bmatrix} \begin{bmatrix} V_1^T \\ V_2^T \end{bmatrix} \Rightarrow \begin{bmatrix} V_1^T \\ V_2^T \end{bmatrix} A^T A [V_1 \ V_2] = \begin{bmatrix} \Sigma_r^2 & O \\ O & O \end{bmatrix}$$

$$U_1^T U_1 = I_r \leftarrow \Sigma_r^{-1} V_1^T A^T \boxed{A V_1 \Sigma_r^{-1}} = I_r \leftarrow \begin{bmatrix} V_1^T A^T A V_1 & \dots \\ \dots & V_2^T A^T A V_2 \end{bmatrix}$$

$A V_2 = O \leftarrow$

$$\begin{bmatrix} V_1^T \\ V_2^T \end{bmatrix} A^T A [V_1 \ V_2] = \begin{bmatrix} \Sigma_r^2 & O \\ O & O \end{bmatrix} \Rightarrow \begin{matrix} AV_2 = O \\ \text{设 } U_1 = AV_1 \Sigma_r^{-1}, \end{matrix}$$

$U_1$  为  $m \times r$  列正交阵

$U_1^T U_1 = I_r$

根据  $U_1$  补齐正交单位向量得到正交阵  $U = [U_1 \ U_2]$

$$U^T AV = \begin{bmatrix} U_1^T \\ U_2^T \end{bmatrix} A [V_1 \ V_2] = \begin{bmatrix} U_1^T AV_1 & U_1^T AV_2 \\ U_2^T AV_1 & U_2^T AV_2 \end{bmatrix} = \begin{bmatrix} U_1^T AV_1 & O \\ U_2^T AV_1 & O \end{bmatrix}$$

$$U_1 = AV_1 \Sigma_r^{-1} \Rightarrow \begin{matrix} AV_1 = U_1 \Sigma_r & \Rightarrow & U_1^T AV_1 = \Sigma_r \\ U_2^T AV_1 = U_2^T U_1 \Sigma_r = O \end{matrix}$$

所以,  $U^T AV = \begin{bmatrix} \Sigma_r & O \\ O & O \end{bmatrix} = \Sigma$       矩阵  $\Sigma$  是唯一确定的

$$A = U \Sigma V^T$$

# 奇异值分解(SVD)的简化形式

Matlab: `[U, S, V] = svd(A);`  
`S = svd(A);`

$$A = U_{m \times m} \sum_{m \times n} V_{n \times n}^T =$$

□ 简化SVD分解

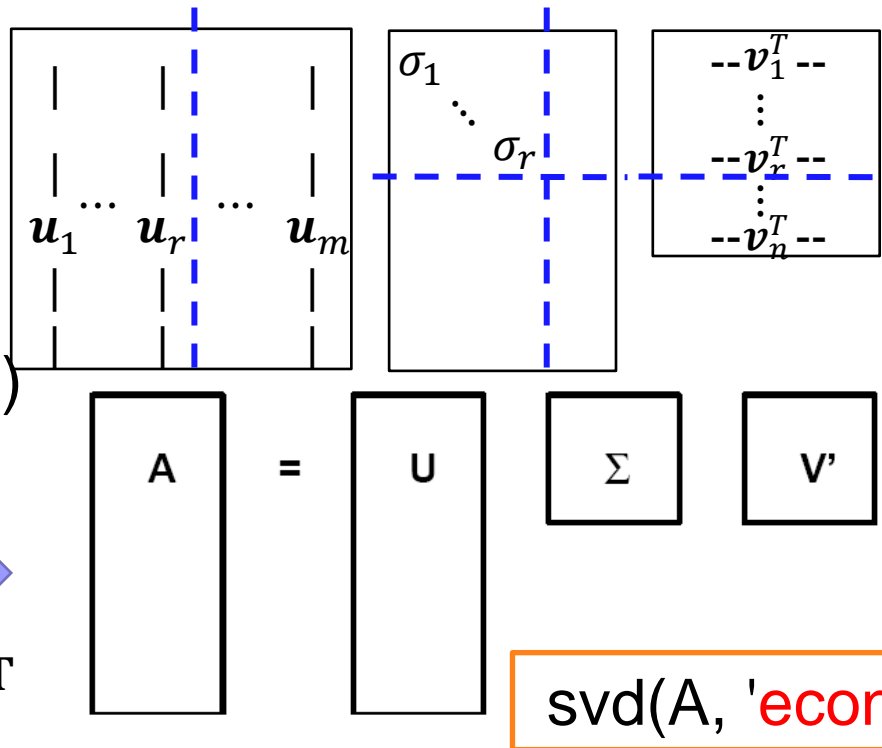
$$A = U_{m \times r} \sum_{r \times r} V_r^T_{r \times n}$$

□ 一般秩r不确定,  $\leq \min(m, n)$   
 简化SVD为 (以  $m > n$  为例)

$$A = U_n \sum_n V^T \quad \rightarrow$$

$$A^T A = V \Sigma_n^T \Sigma_n V^T = V \Sigma_n^2 V^T$$

□ 奇异值  $\sigma_k$  是  $AA^T$  或  $A^T A$  的特征值的算术平方根




# 奇异值分解(SVD)

## ■ 奇异向量的意义

$$A = U \Sigma V^T \quad \begin{cases} AV = U\Sigma \\ A^T U = V\Sigma^T \end{cases}$$

$m \times m \quad m \times n \quad n \times n$

- $A$ 的秩为 $r$ ,  $Av_1 = \sigma_1 u_1, \dots, Av_r = \sigma_r u_r, Av_{r+1} = 0, \dots, Av_n = 0$
- $A^T = V \Sigma U^T$ ,  $A^T u_1 = \sigma_1 v_1, \dots, A^T u_r = \sigma_r v_r, A^T u_{r+1} = 0, \dots, A^T u_m = 0$
- 四个重要子空间的单位正交基





# 奇异值分解(SVD)

## ■ 奇异值与2-范数/F-范数

$$y = [y_1 \ 0 \ \dots \ 0]^T$$

最大  
奇异值

$$\|A\|_2 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \max_{x \neq 0} \frac{\|U \Sigma V^T x\|_2}{\|x\|_2} = \max_{x \neq 0} \frac{\|\Sigma V^T x\|_2}{\|V^T x\|_2} = \max_{y \neq 0} \frac{\|\Sigma y\|_2}{\|y\|_2} = \sigma_1$$

若A非奇异方阵,  
其奇异值均>0

$$\|A^{-1}\|_2 = 1/\sigma_n \longrightarrow \text{cond}(A)_2 = \frac{\sigma_1}{\sigma_n}$$

奇异值范围反映矩阵接近奇异的程度

$$\|A\|_F = (\sum_k \sum_j a_{kj}^2)^{1/2}$$


$$\|A\|_F = \sqrt{\text{tr}(A^T A)} = \sqrt{\sum_{k=1}^n \lambda_k(A^T A)} = \sqrt{\sum_{k=1}^{\min(m,n)} \sigma_k^2}$$

$$\|A\|_F \geq \|A\|_2$$

# 奇异值分解(SVD)

## ■ SVD的向量外积和形式

$$A = [\mathbf{u}_1 \cdots \mathbf{u}_m] \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix} \begin{bmatrix} \mathbf{v}_1^T \\ \vdots \\ \mathbf{v}_n^T \end{bmatrix} = [\sigma_1 \mathbf{u}_1 \cdots \sigma_n \mathbf{u}_n] \begin{bmatrix} \mathbf{v}_1^T \\ \vdots \\ \mathbf{v}_n^T \end{bmatrix} = \sum_{k=1}^n \sigma_k \mathbf{u}_k \mathbf{v}_k^T$$

  
 $A_r = \sum_{k=1}^r \sigma_k \mathbf{u}_k \mathbf{v}_k^T$

**Eckart-Young定理:** 所有秩为 $r$ 的矩阵中 $A_r$ 最接近 $A$

$$A_r \equiv U_r \Sigma_r V_r^T = \sum_{k=1}^r \sigma_k \mathbf{u}_k \mathbf{v}_k^T$$

$$\|A - A_r\|_2 = \sigma_{r+1} \quad \|A - A_r\|_F = \sqrt{\sum_{k=r+1}^{\min(m,n)} \sigma_k^2}$$