

矩阵特征值问题

- 矩阵特征值与特征向量的计算
- 矩阵特征值=特征多项式方程的解 \longrightarrow 一定是迭代解法
- 内容
 - 基本概念与特征值的分布
 - 幂法与反幂法
 - 计算所有特征值的QR迭代算法



矩阵特征值有关概念

基本概念

- 矩阵 A 的**特征值**与**特征向量**, (A 为 $n \times n$ 方阵)

$$Ax = \lambda x, \quad x \neq 0$$

- 特征值 λ 是**特征方程**的根, 复数域内有 n 个(含重根)

$$\det(\lambda I - A) = \begin{vmatrix} \lambda - a_{11} & -a_{12} & \cdots & -a_{1n} \\ -a_{21} & \lambda - a_{22} & \cdots & -a_{2n} \\ \cdots & \cdots & \cdots & \cdots \\ -a_{n1} & -a_{n2} & \cdots & \lambda - a_{nn} \end{vmatrix} = 0$$

- **特征值谱** $\lambda(A)$: A 的全体特征值的集合
- 给定一特征值 λ , **特征向量**是方程 $(\lambda I - A)x = 0$ 的**非零解**
- 对任一特征值, 特征向量都不唯一, 构成**特征子空间**
- 假设 $A \in \mathbb{R}^{n \times n}$
 - 特征值不一定是实数;
 - 实特征值一定可对应实特征向量;
 - 非实特征值的共轭也是特征值, 其对应的特征向量一定不是实向量.

例（根据定义计算特征值、特征向量）：求矩阵的特征值和特征向量。

$$A = \begin{bmatrix} 5 & -1 & -1 \\ 3 & 1 & -1 \\ 4 & -2 & 1 \end{bmatrix}$$

【解】矩阵 A 的特征方程为

$$\det(\lambda I - A) = \begin{vmatrix} \lambda - 5 & 1 & 1 \\ -3 & \lambda - 1 & 1 \\ -4 & 2 & \lambda - 1 \end{vmatrix} = (\lambda - 3)(\lambda - 2)^2 = 0,$$

A 的特征值为 $\lambda_1 = 3, \lambda_2 = 2$ (二重特征值)。

• 当 $\lambda = \lambda_1 = 3$ 时, 由 $(\lambda I - A)x = 0$, 得到方程 $\begin{bmatrix} -2 & 1 & 1 \\ -3 & 2 & 1 \\ -4 & 2 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix},$

它有无穷多个解, 若假设 $x_1 = 1$, 则求出解为 $x = [1, 1, 1]^T$, 记为 x_1 , 则 x_1 是 λ_1 对应的一个特征向量。

• 当 $\lambda = \lambda_2 = 2$ 时, 由 $(\lambda I - A)x = 0$, 得到方程 $\begin{bmatrix} -3 & 1 & 1 \\ -3 & 1 & 1 \\ -4 & 2 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix},$

它有无穷多个解, 若假设 $x_1 = 1$, 则求出解为 $x = [1, 1, 2]^T$, 记为 x_2 , 则 x_2 是 λ_2 对应的一个特征向量。

定理： 设 $\lambda_j (j = 1, 2, \dots, n)$ 为 n 阶矩阵 A 的特征值, 则

$$(1) \sum_{j=1}^n \lambda_j = \sum_{j=1}^n a_{jj} = \text{tr}(A)。$$

$$(2) \prod_{j=1}^n \lambda_j = \det(A)。$$

$\text{tr}(A)$ 表示矩阵对角线上元素之和, 称为矩阵的**迹 (trace)**。

从结论 (2) 也可以得出:

- 非奇异矩阵特征值均不为 0
- 0 一定是奇异矩阵的特征值

特征值的有关性质

$$Ax = \lambda x, \quad x \neq 0$$

- 非奇异矩阵的特征值 $\neq 0$; 0一定是奇异矩阵的特征值
- $\lambda(A) = \lambda(A^T)$ $\det(\lambda I - A) = \det((\lambda I - A)^T)$
- 若 A 为对角阵或上(下)三角阵, 则其特征值为其对角元
- 若 A 为分块对角阵或分块上(下)三角阵(对角块为方阵), 则

$$\lambda(A) = \bigcup_{j=1}^m \lambda(A_{jj})$$

$$A = \begin{bmatrix} A_{11} & A_{12} & \cdots & A_{1m} \\ & A_{22} & \cdots & A_{2m} \\ & & \ddots & \vdots \\ & & & A_{mm} \end{bmatrix}$$

- 矩阵运算结果的特征值: 设 λ_j 为 A 的特征值, 则

$$\lambda(cA) = \{c\lambda_j\}; \quad \lambda(A + cI) = \{\lambda_j + c\}; \quad \lambda(A^k) = \{\lambda_j^k\}; \quad \lambda(A^{-1}) = \{\lambda_j^{-1}\};$$

矩阵的相似变换 (similarity transformation) 不改变特征值。

设矩阵 A 和 B 为相似矩阵, 即存在非奇异矩阵 X 使得 $B = X^{-1}AX$, 则

(1) 矩阵 A 和 B 的特征值相等, 即 $\lambda(A) = \lambda(B)$ 。

(2) 若 y 为 B 的特征向量, 则相应地, Xy 为 A 的特征向量。

特征值的有关性质

- 设 $A \in \mathbb{R}^{n \times n}$ 有 m 个 ($m \leq n$) 不同的特征值 $\tilde{\lambda}_1, \dots, \tilde{\lambda}_m$, 若 $\tilde{\lambda}_j$ 是特征方程的 n_j 重根, 则称 n_j 为 $\tilde{\lambda}_j$ 的代数重数, $\tilde{\lambda}_j$ 的特征子空间的维数是其几何重数.
- 设 n 阶实方阵 A 的 m 个不同的特征值为 $\tilde{\lambda}_1, \dots, \tilde{\lambda}_m$, $\tilde{\lambda}_j$ 的代数重数为 n_j , 几何重数为 k_j , 则
 - $\sum_j n_j = n$;
 - $\forall j, n_j \geq k_j$
 - 不同特征值的特征向量线性无关, 所有特征子空间的 $\sum_{j=1}^m k_j$ 个基形成一组线性无关向量 (可能少于 n 个)
 - 若 $\forall j, n_j = k_j$, 这种矩阵 A 为非亏损阵, 否则为亏损阵. 非亏损阵有 n 个特征向量构成全空间的基 (\mathbb{C}^n)

特征值的有关性质

- A 为非亏损阵 $\Leftrightarrow \exists X^{-1}AX = \Lambda$, Λ 为对角阵

非奇异矩阵 $X \in \mathbb{C}^{n \times n}$ 列向量为 n 个线性无关的特征向量

$$A = X\Lambda X^{-1} \quad (\text{特征值分解})$$

- (**Jordan分解**): 矩阵 $A \in \mathbb{R}^{n \times n}$

$$A = XJX^{-1},$$

$p = \sum k_j$, k_j 为特征值的几何重数;

$\tilde{\lambda}_j$ 对应 k_j 个约当块, 其阶数之和 = n_j

$$J = \begin{bmatrix} J_1 & & \\ & \ddots & \\ & & J_p \end{bmatrix},$$

(约当标准型)

$$J_s = \begin{bmatrix} \lambda_s & 1 & & \\ & \lambda_s & \ddots & \\ & & \ddots & 1 \\ & & & \lambda_s \end{bmatrix}$$

亏损阵

$1 \leq s \leq p$, 称为约当块, 其对角线元素为矩阵 A 的特征值

Jordan矩阵

$$\begin{bmatrix} -2 & 1 & \\ & -2 & 1 \\ & & -2 \end{bmatrix}, \begin{bmatrix} 0 & 1 & & \\ & 0 & 1 & \\ & & 0 & 1 \\ & & & 0 \end{bmatrix}, \begin{bmatrix} 1-i & 1 & \\ & 1-i & 1 \\ & & 1-i \end{bmatrix} \quad \text{约当块}$$

$$\begin{bmatrix} \boxed{1} & & & \\ & \boxed{2} & & \\ & & \boxed{1-i} & \\ & & & \end{bmatrix}, \begin{bmatrix} 2 & 1 & & \\ & 2 & & \\ & & & 3 \end{bmatrix}, \begin{bmatrix} 1 & 1 & & \\ & 1 & & \\ & & i & 1 \\ & & & i & 1 \\ & & & & i \end{bmatrix}, \begin{bmatrix} \boxed{1} & \boxed{1} & & & \\ & \boxed{1} & & & \\ & & -2 & & \\ & & & -2 & 1 \\ & & & & -2 \end{bmatrix}$$

在约当分解中, 如果所有约当块都是 1 阶的, 则 J 为对角矩阵, 这种分解就是特征值分解

实对称阵为非亏损阵 (可正交对角化)

实对称矩阵 $\mathbf{A} \in R^{n \times n}$ 的特征值均为实数，存在 n 个线性无关且正交的实特征向量，即存在由特征值组成的对角阵 $\mathbf{\Lambda}$ 和由特征向量组成的正交阵 \mathbf{Q} ，使得

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T$$

特征值的分布估计

- 估计特征值的分布范围或它们的界有重要意义

- 迭代法 $\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}$ 的收敛性, 看 $\rho(\mathbf{B}) = \max_j |\lambda_j(\mathbf{B})|$

- 矩阵的2-条件数: $\text{cond}(\mathbf{A})_2 = \sqrt{\frac{\lambda_{\max}(\mathbf{A}^T \mathbf{A})}{\lambda_{\min}(\mathbf{A}^T \mathbf{A})}}$


- $\rho(\mathbf{A}) \leq \|\mathbf{A}\|_v$

- **定义5.4** $\mathbf{A} \in \mathbb{C}^{n \times n}$, 设 $r_k = \sum_{j=1, j \neq k}^n |a_{kj}|$, 在复平面上以 a_{kk} 为圆心、 r_k 为半径的圆, 称为 \mathbf{A} 的 **Gerschgorin 圆盘**

- **Th5.10** (圆盘定理)

- \mathbf{A} 的特征值必在 n 个圆盘并集上

- 若 n 个圆盘中有 m 个连通, 且与其他分离, 则这 m 个圆盘中正好含 m 个特征值



结论(1)的证明:


$$A\mathbf{x} = \lambda\mathbf{x}, \text{ 设 } \mathbf{x} \text{ 的第 } k \text{ 个分量最大} \quad |x_k| = \max_{1 \leq j \leq n} |x_j| > 0,$$

$$\sum_{j=1}^n a_{kj}x_j = \lambda x_k, \quad (\lambda - a_{kk})x_k = \sum_{j \neq k} a_{kj}x_j$$

$$|\lambda - a_{kk}| |x_k| = \left| \sum_{\substack{j=1 \\ j \neq k}}^n a_{kj}x_j \right| \leq \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}| |x_j| \leq |x_k| \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}|$$

$$|\lambda - a_{kk}| \leq \sum_{j \neq k} |a_{kj}|$$

若某个特征向量的第 k 个分量的模最大,则相应的特征值必属于第 k 个圆盘。



- 设 $A \in \mathbb{R}^{n \times n}$, 且 A 的对角元均大于 0, 则
 - (1) 若 A 严格对角占优, 则 A 的特征值的实部都大于 0。
 - (2) 若 A 为对角占优的对称矩阵, 则 A 一定是对称半正定矩阵。若同时 A 非奇异, 则 A 为对称正定矩阵。


圆盘定理的应用

例: 估计矩阵 $A = \begin{bmatrix} 4 & 1 & 0 \\ 1 & 0 & -1 \\ 1 & 1 & -4 \end{bmatrix}$ 的特征值分布, $A^T = \begin{bmatrix} 4 & 1 & 1 \\ 1 & 0 & 1 \\ 0 & -1 & -4 \end{bmatrix}$

D_1 与其他圆盘分离, 则它仅含一个特征值, 且必定为实数 (若为虚数, 则其共轭也是特征值, 这与 D_1 仅含一个特征值矛盾)

D'_3 中存在一个特征值, 且为实数, 它属于区间 $[-5, -3]$

$$\lambda_1 \in [3, 5], \lambda_3 \in [-5, -3], \lambda_2 \in [-2, 2]$$



准确特征值为: 4.2030, -3.7601, -0.4429



幂法与反幂法

计算最大的特征值、特征向量

- 模最大的特征值称为**主特征值**, 也叫“第一特征值”, 记为 λ_1 , 它对应的特征向量称为**主特征向量**

主特征值可能**不唯一**, 例如 $5, -5, 3 + 4i, 3 - 4i$ 的模都是 5
谱半径 \neq 主特征值

- **幂法**(power iteration): 取任意的非零向量 \mathbf{v}_0 , 计算 $\mathbf{v}_k = A\mathbf{v}_{k-1}, (k = 1, 2, \dots)$, 得到向量序列 $\{\mathbf{v}_k\}$

(1) 当 $k \rightarrow \infty$ 时, \mathbf{v}_k 趋近于 λ_1 的特征向量。

(2) $\lim_{k \rightarrow \infty} \frac{(v_{k+1})_j}{(v_k)_j} = \lambda_1, \quad j \text{ 为 } \mathbf{v}_k, \mathbf{v}_{k+1} \text{ 绝对值最大元素的下标}$

幂法

- **定理5.12** 若矩阵 A 有**唯一**的主特征值 λ_1 ($\neq 0$), 取**随机非零**向量 \boldsymbol{v}_0 , 计算 $\boldsymbol{v}_k = A\boldsymbol{v}_{k-1}$, ($k = 1, 2, \dots$), 则:
 $k \rightarrow \infty$, $\boldsymbol{v}_k \rightarrow \lambda_1$ 的某个特征向量

证明: 考虑 A 为非亏损阵的情况

注意: 需要 \boldsymbol{v}_0 对应 $\alpha_1 \neq 0$

设 A 的线性无关的特征向量为 $\hat{\boldsymbol{x}}_1, \dots, \hat{\boldsymbol{x}}_n$, $\boldsymbol{v}_0 = \alpha_1 \hat{\boldsymbol{x}}_1 + \dots + \alpha_n \hat{\boldsymbol{x}}_n$
 $\boldsymbol{v}_k = A^k \boldsymbol{v}_0 = \alpha_1 \lambda_1^k \hat{\boldsymbol{x}}_1 + \dots + \alpha_n \lambda_n^k \hat{\boldsymbol{x}}_n = \lambda_1^k \left[\sum_{j=1}^s \alpha_j \hat{\boldsymbol{x}}_j + \sum_{j=s+1}^n \alpha_j \left(\frac{\lambda_j}{\lambda_1} \right)^k \hat{\boldsymbol{x}}_j \right]$ **模 <1**
 $\therefore \boldsymbol{v}_k$ 趋向于某主特征向量的倍数 (设 λ_1 为 s 重特征值)

若 j 为 \boldsymbol{v}_k , \boldsymbol{v}_{k+1} 绝对值最大元素的下标, $\lim_{k \rightarrow \infty} \frac{(\boldsymbol{v}_{k+1})_j}{(\boldsymbol{v}_k)_j} = \lambda_1$

幂法

$$\boldsymbol{v}_k = A\boldsymbol{v}_{k-1}$$

■ 关于幂法的说明

- A 为亏损矩阵的情况, 可以用矩阵的Jordan分解进行证明
- $\{\boldsymbol{v}_k\}$ 相邻项的第 j 分量比值 \rightarrow 主特征值, 选最大分量 $\neq 0$
- 在实际应用时随机选取 \boldsymbol{v}_0 , 避免出现特殊情况

■ 幂法的问题

$\boldsymbol{v}_k \approx \lambda_1^k \boldsymbol{x}_1$, k 很大时, 可能出现上溢或下溢

$$\boldsymbol{v}_k = \lambda_1^k \left[\sum_{j=1}^s \alpha_j \hat{\boldsymbol{x}}_j + \sum_{j=s+1}^n \alpha_j \left(\frac{\lambda_j}{\lambda_1} \right)^k \hat{\boldsymbol{x}}_j \right], \quad \text{收敛速度主要取决于} \left| \frac{\tilde{\lambda}_2}{\lambda_1} \right|$$

$\tilde{\lambda}_2$ 为仅小于 λ_1 的特征值

■ 实用的幂法: 用规格化向量的技术防止溢出

规格化向量

- **定义5.6** 记 $\overline{\max}(v)$ 为向量 v 的绝对值最大分量, 若不唯一则取编号最小的那个. 称 $u = v / \overline{\max}(v)$ 为向量 v 的规格化向量

例: $v = [3, -5, 0]^T$, $\overline{\max}(v) = -5$, 规格化向量为 $u = \left[-\frac{3}{5}, 1, 0\right]^T$

- 若 u 为规格化向量, 则 $\|u\|_{\infty} = 1$, $\overline{\max}(u) = 1$
- 向量 v_1, v_2 的规格化向量分别为 u_1, u_2 , 若 $v_1 = \alpha v_2$, 则 $u_1 = u_2$

规格化也可以使用其他范数代替 $\overline{\max}(v)$

实用的幂法

- 在幂法的每步增加向量规格化, 避免上溢或下溢

$$\begin{aligned} v_1 = Av_0 & \xrightarrow{\quad} \text{规格化向量 } u_1 = \frac{v_1}{\overline{\max}(v_1)} = \frac{Av_0}{\overline{\max}(Av_0)} \\ v_2 = Au_1 = \frac{A^2v_0}{\overline{\max}(Av_0)} & \xrightarrow{\quad} \text{规格化向量 } u_2 = \frac{v_2}{\overline{\max}(v_2)} = \frac{A^2v_0}{\overline{\max}(A^2v_0)} \\ v_k = Au_{k-1} = \frac{A^kv_0}{\overline{\max}(A^{k-1}v_0)} & \xrightarrow{\quad} u_k = \frac{v_k}{\overline{\max}(v_k)} = \frac{A^kv_0}{\overline{\max}(A^kv_0)} \quad k = 1, 2, \dots \end{aligned}$$

$$\lim_{k \rightarrow \infty} u_k = \frac{x_1}{\overline{\max}(x_1)}$$

$$\lim_{k \rightarrow \infty} \overline{\max}(v_k) = \lambda_1$$

x_1 为某个主特征向量

实用的幂法

- **算法5.1:**计算主特征值 λ_1 和主特征向量 x_1 的实用幂法

输入: A ; 输出: x_1, λ_1 .

u : = 随机向量;

While 不满足判停准则 **do**

v : = Au ;

λ_1 : = $\max(v)$; {主特征值近似值}

u : = v/λ_1 ; {规格化}

End

x_1 : = u . {规格化的主特征向量}

每步的主要计算
是算一次矩阵与
向量乘法

对稀疏阵 A 很友好

- 可用相邻两步得到的 λ_1 之差作判停准则
 - 规格化保证数值不上/下溢, 绝对值最大分量收敛到 λ_1
 - 前提条件: 主特征值唯一
- 迭代步数少时可不作规格化,
规格化也可改为 $v/\|v\|$

例：用实用的幂法求矩阵的主特征值， $A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$

取初始向量为 $v_0 = u_0 = [0 \ 1]^T$ 。迭代过程的计算结果：


k	v_k^T		$\overline{max}(v_k)$	u_k^T	
0				0.000	1.0
1	1.0	3.000	3.000	0.333	1.0
2	2.0	3.333	3.333	0.600	1.0
3	2.800	3.600	3.600	0.778	1.0
4	3.333	3.778	3.778	0.882	1.0
5	3.647	3.882	3.882	0.939	1.0
6	3.818	3.939	3.939	0.969	1.0
7	3.908	3.969	3.969	0.984	1.0
8	3.953	3.984	3.984	0.992	1.0
9	3.977	3.992	3.992	0.996	1.0

加速幂法的收敛

■ 原点位移技术

- $B = A - sI$ 的特征值为 A 的特征值 $-s$
对 B 应用幂法可能加快收敛

- 如图中 A 的特征值分布, $\left| \frac{\tilde{\lambda}_2 - s}{\lambda_1 - s} \right| < \left| \frac{\tilde{\lambda}_2}{\lambda_1} \right|$, 更快收敛



■ 瑞利商(Rayleigh quotient)加速

- 实对称阵 A 的瑞利商: $R(\mathbf{x}) = \frac{\langle A\mathbf{x}, \mathbf{x} \rangle}{\langle \mathbf{x}, \mathbf{x} \rangle} = \frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}}$
- 对实对称阵 A , $\lambda_n \leq R(\mathbf{x}) \leq \lambda_1$, λ_1 (λ_n) 为最大(最小)特征值;
若 \mathbf{x} 为相应特征向量, 不等号变等号 “实对称阵可正交对角化”
- 实对称阵的主特征值 λ_1 唯一, 则幂法中规格化向量 \mathbf{u}_k 满足
$$R(\mathbf{u}_k) = \lambda_1 + O\left(\left(\tilde{\lambda}_2/\lambda_1\right)^{2k}\right) \quad \text{注意: 幂法, } \sim \lambda_1 + O\left(\left(\tilde{\lambda}_2/\lambda_1\right)^k\right)$$
- 在幂法基础上, 每步对 \mathbf{u}_k 计算 $R(\mathbf{u}_k) \approx \lambda_1$

例 对于前例中的问题, 采用瑞利商加速技术的幂法计算主特征值。

k	$\overline{max}(v_k)$	u_k^T		$\frac{u_k^T A u_k}{u_k^T u_k}$
0		0.000	1.0	3.000
1	3.000	0.333	1.0	3.600
2	3.333	0.600	1.0	3.882
3	3.600	0.778	1.0	3.969
4	3.778	0.882	1.0	3.992
5	3.882	0.939	1.0	3.998
6	3.939	0.969	1.0	4.000

反幂法

- A^{-1} 的特征值是 A 特征值的倒数, 对 A^{-1} 应用幂法得最小特征值

算法5.2 算最小特征值/特征向量的反幂法

输入: A ; **输出:** x_n, λ_n .

u : = 随机向量;

While 不满足判停准则 **do**

v : = $A^{-1}u$; {求解线性方程组}

λ_n : = $1/\overline{\max}(v)$; {最小特征值的近似值}

u : = $\lambda_n v$; {规格化}

End

x_n : = u . {规格化的特征向量}

求解线性方程组, 计算量可能比幂法大很多

- 适用范围: A 按模最小的特征值唯一
- 与原点位移技术结合: 若已知某个特征值 $\lambda_j \approx p$, 则 $\lambda_j - p$ 是 $B = A - pI$ 按模最小的特征值, 对 B 使用反幂法

例 用反幂法求前例中矩阵的按模最小特征值。

k	\mathbf{u}_k^T		$\overline{max}(\mathbf{v}_k)$
0	0.000	1.0	
1	-0.333	1.0	0.375
2	-0.600	1.0	0.417
3	-0.778	1.0	0.450
4	-0.882	1.0	0.472
5	-0.939	1.0	0.485
6	-0.969	1.0	0.492
7	-0.984	1.0	0.496
8	-0.992	1.0	0.498
9	-0.996	1.0	0.499

小结

■ 实用幂法可能失败的情况

- 矩阵 A 的主特征值不唯一, 例如某个实矩阵, 其模最大的特征值有不只一个数 (相反数、成对虚数)
- 反幂法的情况类似

■ 说明几点

- 按幂法迭代计算, 若前后两次迭代向量成比例, 则它一定就是特征向量, 也相应求出特征值
- 加速幂法的方法还有Aitken外推等算法
- 反幂法与位移技术结合, 是很重要的技术



QR迭代算法

计算矩阵的所有特征值

■ 两个问题

□ 什么样的矩阵易于求所有特征值?

□ 对矩阵做怎样的变换能保持特征值不变?

$$X^{-1}AX$$
$$Q^T A Q$$

■ 思路: 用正交相似变换化矩阵为三角阵或分块三角阵

■ 收缩技术(deflation)

□ 若已知 A 的一个特征向量 x (比如通过幂法/反幂法)

□ 用正交变换将 x 消元: $Hx = \sigma e_1$, 则 e_1 是 HAH^T 的特征向量

$$HAH^T e_1 = HA \left(\frac{1}{\sigma} x \right) = \frac{1}{\sigma} H A x = \frac{1}{\sigma} H \lambda x = \frac{\lambda}{\sigma} (\sigma e_1) = \lambda e_1$$

$$\begin{bmatrix} \lambda & r_1^T \\ 0 & A_1 \end{bmatrix}$$

问题变小!

计算矩阵的所有特征值

- 收缩技术的例子: 已知 $A = \begin{bmatrix} 3 & -1 & 1 \\ 2 & 0 & 1 \\ 1 & -1 & 2 \end{bmatrix}$ 的一个特征值为

$\lambda_1 = 2$, 对应特征向量为 $x_1 = [1, 1, 0]^T$, 求其他特征值

解: 用Householder变换对 x_1 消元, 相应的 $\sigma = \sqrt{2} = 1.4142$

构造矩阵 H 的 v 向量为: $v = x_1 + \sigma e_1 = \begin{bmatrix} 2.4142 \\ 1 \\ 0 \end{bmatrix}$

$$\Rightarrow H = \begin{bmatrix} -0.7072 & -0.7072 & 0 \\ -0.7072 & 0.7072 & 0 \\ 0 & 0 & 1 \end{bmatrix}, HAH^T = \begin{bmatrix} 2 & 3 & -1.4142 \\ 0 & 1 & 0 \\ 0 & -1.4142 & 2 \end{bmatrix}$$

易知 A_1 的特征值为 1, 2, 得到 A 的所有特征值

□ 不形成 H 计算 HAH^T : 先算 $B = HA^T$, 再 $HAH^T = HB^T$

用收缩技术+幂法效率不高, 而且会误差累积, 使结果不准。

QR迭代算法

1959~1961, John G.F. Francis和
Vera N. Kublanovskaya各自发明

■ 理论基础

- **Th5.21**(实Schur分解): $\forall A \in \mathbb{R}^{n \times n}$, \exists 正交阵 Q 使 $Q^T A Q = S$, S 为拟上三角阵
- 拟上三角阵即实Schur型: 对角块为1阶或2阶的分块上三角阵
2阶对角块的特征值是 A 的两个共轭复特征值
- 思路: 用一系列正交相似变换 $B = Q^T A Q$, 逐渐将 A 化为上三角或对角块阶数 ≤ 2 的分块上三角矩阵

■ QR算法 (“二十世纪十大算法”之一)

$\left\{ \begin{array}{l} \text{对 } A_k \text{ 做QR分解: } A_k = Q_k R_k \\ A_{k+1} = R_k Q_k, (k = 0, 1, \dots) \end{array} \right.$ 生成正交相似矩阵序列 $\{A_k\}$

$$A_{k+1} = Q_k^T A_k Q_k$$

QR迭代算法

算法5.4: 计算矩阵特征值的QR算法

输入: A ;

输出: $\lambda_1, \dots, \lambda_n$.

While A 不是拟上三角阵 **do**

 计算 A 的QR分解, 得到矩阵 Q 和 R ;

$A := RQ$;

End

根据 A 的对角块求特征值 $\lambda_1, \dots, \lambda_n$.

QR迭代算法

基本上是幂法收敛条件的推广
(否则, 对角块数可能 >2)



■ Th5.22: 收敛定理

- 若矩阵 A 的等模的特征值为实重特征值或复共轭特征值, \dots , 则QR迭代所得矩阵序列 $\{A_k\}$ 基本收敛于拟上三角阵

“基本收敛”

$$\begin{bmatrix} \times & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & 0 & 0 & \times \end{bmatrix}$$

正交相似变换保对称性: 若 A 对称, 则 $Q^T A Q$ 也对称

对实对称阵做QR迭代, 若满足Th5.22条件, 则极限为对角阵

实用的QR算法

■ QR算法的不足之处

- 每步迭代的计算量很大 将矩阵化简为上Hessenberg阵
- 可能不收敛, 或收敛很慢 带原点位移的QR迭代

■ 如果矩阵是上Hessenberg型 $\begin{bmatrix} \times & \times & \times & \times \\ \times & \times & \times & \times \\ & \times & \times & \times \\ & & \times & \times \end{bmatrix}$

- 对它执行QR迭代算法, 其中QR分解应用Givens旋转, 每步计算由 $O(n^3)$ 降为 $O(n^2)$

设 P_1, P_2, \dots, P_{n-1} 为Givens旋转阵, A_k 为上Hessenberg阵

$$P_{n-1} \cdots P_2 P_1 A_k = R_k \Rightarrow Q_k = (P_{n-1} \cdots P_2 P_1)^T$$

$$A_{k+1} = R_k Q_k = P_{n-1} \cdots P_2 P_1 A_k (P_{n-1} \cdots P_2 P_1)^T$$

$$= P_{n-1} \cdots P_2 P_1 A_k P_1^T P_2^T \cdots P_{n-1}^T \quad A_{k+1} \text{ 仍是上Hessenberg阵}$$

实用的QR算法

- 将A正交相似约化为上Hessenberg

- 用Householder变换

$$Q^T A Q$$

$$\begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \end{bmatrix} \rightarrow \begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ & \times & \times & \times & \times \\ & & \times & \times & \times \\ & & & \times & \times \end{bmatrix}$$

$$A = \begin{bmatrix} a_{11} & \mathbf{r}_1^T \\ \mathbf{c}_1 & A_{22}^{(1)} \end{bmatrix} \xrightarrow{H_1 = \begin{bmatrix} 1 & \mathbf{0}^T \\ \mathbf{0} & H'_1 \end{bmatrix}} H_1 A = \begin{bmatrix} a_{11} & \mathbf{r}_1^T \\ \sigma_1 \mathbf{e}_1 & H'_1 A_{22}^{(1)} \end{bmatrix} \rightarrow H_1 A H_1 = \begin{bmatrix} a_{11} & \mathbf{r}_1^T H'_1 \\ \sigma_1 \mathbf{e}_1 & H'_1 A_{22}^{(1)} H'_1 \end{bmatrix}$$


$$A^{(2)} = \begin{bmatrix} a_{11} & a_{12}^{(2)} & a_{13}^{(2)} & \cdots & a_{1n}^{(2)} \\ \sigma_1 & a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2n}^{(2)} \\ \hline 0 & a_{32}^{(2)} & a_{33}^{(2)} & \cdots & a_{3n}^{(2)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & a_{n2}^{(2)} & a_{n3}^{(2)} & \cdots & a_{nn}^{(2)} \end{bmatrix} \xrightarrow{H_2 = \begin{bmatrix} I_2 & \mathbf{0}^T \\ \mathbf{0} & H'_2 \end{bmatrix}} H_2 A^{(2)} H_2 = \begin{bmatrix} a_{11} & a_{12}^{(2)} & a_{13}^{(3)} & \cdots & \cdots & a_{1n}^{(3)} \\ \sigma_1 & a_{22}^{(2)} & a_{23}^{(3)} & \cdots & \cdots & a_{2n}^{(3)} \\ \hline 0 & \sigma_2 & a_{33}^{(3)} & \cdots & \cdots & a_{3n}^{(3)} \\ 0 & 0 & \vdots & \ddots & & \vdots \\ \vdots & \vdots & \vdots & & \ddots & \vdots \\ 0 & 0 & a_{n3}^{(3)} & \cdots & \cdots & a_{nn}^{(3)} \end{bmatrix}$$

... ..

- 最终 $H_{n-2} \cdots H_1 A H_1 \cdots H_{n-2}$ 为上Hessenberg阵

实用的QR算法

- 实对称矩阵 A



- 带原点位移的QR迭代(改善收敛)

□ 单位移技术 $\begin{cases} Q_k R_k = A_k - s_k I, & \text{(作QR分解)} \\ A_{k+1} = R_k Q_k + s_k I, & k = 0, 1, 2, \dots \end{cases}$

$$A_{k+1} = R_k Q_k + s_k I$$

$$= Q_k^T (A_k - s_k I) Q_k + s_k I = Q_k^T A_k Q_k \longrightarrow \{A_k\} \text{ 仍两两正交相似}$$

□ 简单策略: 取 $s_k = A_k(n, n)$, 加速收敛

□ 非对称阵有复特征值, 采用双位移